strojno učenje

1. KONTROLNA ZADACA

1. Britansko vijece za klasifikaciju filmova (*British Board of Film Classification*, BBFC) klasificira svaki film prije njegove distribucije u skladu s nekoliko zakonskih akata ciji je cilj sprjecavanje prikazivanja štetnog i nemoraln og sadržaja mladim osobama. Postoji ukupno sedam kategorija, od kojih su tri nerestriktivne i omogucavaju prikazivanje filmova djeci mladoj od 12 godina uz eventualnu pratnju roditelja: *U, Uc* (universal) i *PG* (parental guidance). BBFC klasifikaciju cini na temelju osam atributa koji opisuju filmski sadržaj.

Ogranicimo se ovdje na cetiri atributa. Atributi i njihove vrijednosti neka su sljedeci:

violence = (none, mild, detailed)
nudity = (none, mild, explicit)
horror = (none, occasional, sustained)

drugs = (no, yes)

Skup primjera za ucenje i vrijednost ciljnog atributa za svaki pojedini primjer (pripada li film bilo u U, Uc ili PG kategoriju, ili ne pripada) neka je sljedeci:

violence	nudity	horror	drugs	U/Uc/PG
1. detailed	none	none	yes	no
2. none	none	none	no	yes
3. mild	none	occasional	yes	no
4. mild	mild	sustained	no	no
5. none	none	occasional	no	yes
6. detailed	explicit	none	no	no
7. mild	mild	none	no	yes
8. none	mild	sustained	no	no

- a) Nadi maksimalno specificnu hipotezu pomocu PRONAĐI-S algoritma. Hipoteza neka je predstavljena kao konjunkcija uvjeta nad atributima. Svaki korak algoritma potrebno je opisati. Primjere predocavati redoslijedom kojim su navedeni.
- Za svaki od navedenih primjera za ucenje odredi da li je konzistentan s dobivenom hipotezom i da li je zadovoljava.

(none, mild, occasional, no) = yes (detailed, mild, sustained, yes) = no (mild, none, none, no) = no

strojno učenje

25%

- a) Pomocu algoritma eliminacije kandidata nadi prostor inacica za skup primjera iz zadatka 1. Hipoteze neka su predstavljene kao konjunkcija uvjeta nad atributima. Primjere predocavati redoslijedom kojim su navedeni.
- b) Komentiraj razliku dobivenog rezultata u odnosu na rezultat dobiven PRONAĐI-S algoritmom.
- c) U kojem se dijelu prostora primjera (X\G, G\S, S) opcenito treba nalaziti novi primjer a da se prostor inacica promijeni. Razmotrite primjere koji su konzistentni s ciljnim konceptom i one koji nisu.
- d) Pretpostavi da se u skup primjera za ucenje doda deveti primjer:

```
(detailed, explicit, sustained, yes) = no
```

Opiši i obrazloži kakav utjecaj ima ovaj primjer na rezultat dobiven PRONAĐI-S algoritmom i algoritmom eliminacije kandidata. Kakav je opceniti utjecaj negativnog primjera na rezultate tih dvaju algoritama?

5. 15%

- a) Graficki prikaži prostor inacica dobiven algoritmom eliminacije kandidata iz zadatka 2 nakon predocavanja šestog primjera za ucenje.
- **b**) Pretpostavi da je postupak ucenja završen nakon predocavanja šestog primjera. Opiši kako ce sustav klasificirati sljedece primjere:

```
(none, none, sustained, no)
(none, mild, sustained, no)
(mild, none, sustained, yes)
(detailed, none, occasional, yes)
```

- c) Pretpostavi da sustav može sam ciniti upite o klasifikaciji pojedinih primjera. Koja je optimalna strategija generiranja upita?
- 4. 30%
- a) Nacini graficku reprezentaciju stabla odluke pomocu ID3 algoritma za skup primjera za ucenje iz zadatka 1. Potrebno je napisati detaljan ispis postupka izracuna.
- b) Komentiraj razliku dobivenog rezultata u odnosu na rezultat dobiven algoritmom eliminacije kandidata.
- **c**) Komentiraj razliku između ID3 algoritma i algoritma eliminacije kandidata s obzirom na dostupnost primjera za ucenje (situacija kada su svi primjeri odmah dostupni i kada nisu). Koji algoritam je pogodniji za *on-line* ucenje?
- 5. Što cini induktivnu pristranost PRONAĐI-S algoritma, algoritma eliminacije kandidata i ID3 algoritma? Nacini usporedbu tih pristranosti.