

Strojno učenje – međuispit

UNIZG FER, ak. god. 2013./2014.

21. studenog 2013.

Napomena: Ispit traje 180 minuta i nosi 35 bodova. Svaki zadatak rješavajte na zasebnoj stranici.

1. (3 boda) Osnovni koncepti nadziranog učenja.

- (a) Nabrojite (bez opisivanja) tri osnovne komponente algoritma nadziranog strojnog učenja. Koja od tih komponenti uvodi koju vrstu induktivne pristranosti?
- (b) Obrazložite u kakvim su odnosima (i) složenost modela, (ii) broj parametara modela i (iii) broj primjera za učenje.

2. (5 bodova) Prostor inačica i VC-dimenzija.

- (a) Model $h(\mathbf{x}|\boldsymbol{\theta}) = \mathbf{1}\{(x_1 - \theta_1)^2 + (x_2 - \theta_2)^2 \leq \theta_0\}$, gdje $\boldsymbol{\theta} \in \mathbb{R}^3$, koristimo za klasifikaciju u prostoru $\mathcal{X} = \mathbb{Z}^2$. Raspolažemo skupom primjera: $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), 0), ((2, 3), 0), ((1, 2), 1), ((2, 2), 1)\}$. Odredite klasifikaciju primjera $\mathbf{x} = (1, 4)$ te odredite skup prostora inačica $VS_{\mathcal{H}, \mathcal{D}}$.
- (b) Formalno definirajte VC-dimenziju modela \mathcal{H} i objasnite zašto je ta karakterizacija složenosti modela u praksi problematična.
- (c) Odredite VC-dimenziju modela pod (a).
- (d) Redefinirajte model pod (a) tako da (i) prostor inačica sadrži samo jednu hipotezu (model \mathcal{H}_1) i (ii) povećate VC-dimenziju modela (model \mathcal{H}_2).

3. (4 boda) Odabir modela.

- (a) Definirajte prenaučenosť modela i u jednoj rečenici objasnite zašto ne želimo prenaučene modele.
- (b) Raspolažemo modelom \mathcal{H}_α koji ima hiperparametar α kojim se može ugađati složenost modela. Odabrali smo dva modela, \mathcal{H}_{α_1} i \mathcal{H}_{α_2} , oba trenirana istim algoritmom L . Pogreške na skupu za učenje su takve da $E(h_2|\mathcal{D}) < E(h_1|\mathcal{D})$. Koji biste model odabrali i zašto?
- (c) Raspolažemo dvama algoritmima strojnog učenja, L_1 i L_2 . Algoritam L_1 analitički optimizira parametre modela, dok algoritam L_2 parametre optimizira heuristički i sklon je zaglavljivanju u lokalnom optimumu tako da u više od 50% slučajeva nalazi suboptimalne parametre. Skicirajte funkciju empirijske pogreške i pogrešku generalizacije u ovisnosti o složenosti modela za algoritme L_1 i L_2 .

4. (5 bodova) Procjenitelji.

- (a) Definirajte funkciju log-izglednosti $\ln \mathcal{L}(\boldsymbol{\theta}|\mathcal{D})$ i izračunajte $\ln \mathcal{L}(\mu = 0, \sigma^2 = 1|\mathcal{D})$ za skup primjera $\mathcal{D} = \{0, 1, 2\}$ uz pretpostavku Gaussove razdiobe $p(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$.
- (b) Definirajte procjenitelje $\hat{\boldsymbol{\theta}}_{\text{ML}}$ i $\hat{\boldsymbol{\theta}}_{\text{MAP}}$ te ukratko objasnite prednost drugog nad prvim.
- (c) Izvedite, korak po korak, ML-procjenitelj za parametar μ univarijatne Gaussove razdiobe.
- (d) U deset bacanja novčića ($N = 10$) dva puta smo dobili glavu ($m = 2$). Apriornu razdiobu parametra μ Bernoullijeve razdiobe modeliramo beta-distribucijom $p(\mu|\alpha, \beta) = \mu^{\alpha-1}(1-\mu)^{\beta-1}/B(\alpha, \beta)$ uz $\alpha = \beta = 2$. Skicirajte funkciju izglednosti, gustoće $p(\mu)$ i $p(\mu|\mathcal{D})$ te odredite $\hat{\mu}_{\text{MAP}}$ i $\hat{\mu}_{\text{Bayes}}$. Iskoristite činjenicu da je mod beta-distribucije jednak $\frac{\alpha-1}{\alpha+\beta-2}$ a očekivanje $\frac{\alpha}{\alpha+\beta}$.
- (e) Iz bayesovskog procjenitelja izvedite Laplaceov procjenitelj za Bernoullijevu varijablu.

5. (5 boda) Bayesov klasifikator za diskretne ulaze.

- (a) Definirajte naivan Bayesov klasifikator i napišite općenit izraz za broj parametara tog modela.
- (b) Poruke el. pošte klasificiramo u dvije klase: *spam* (\mathcal{C}_1) i *no-spam* (\mathcal{C}_2). Pogrešna klasifikacija *no-spam* poruke kao *spam* je deset puta nepoželjnija od ostalih pogrešaka. Definirajte matricu gubitka L i izračunajte klasifikaciju poruke \mathbf{x} ako $P(\mathbf{x}|\mathcal{C}_1) = 0.7$, $P(\mathbf{x}|\mathcal{C}_2) = 0.1$ i $P(\mathcal{C}_1) = 0.8$.
- (c) Učimo polunaivan Bayesov klasifikator za klasifikaciju primjera iz $\{0, 1\}^5$ u dvije klase. Na temelju skupa primjera \mathcal{D} dobili smo sljedeće procjene za mjeru uzajamne informacije:

$$\begin{aligned} I(x_5, \mathcal{C}) &> I(x_4, \mathcal{C}) > I(x_2, \mathcal{C}) > I(x_1, \mathcal{C}) > I(x_3, \mathcal{C}) \\ I(x_3, x_5|\mathcal{C}) &> I(x_2, x_4|\mathcal{C}) > I(x_2, x_3|\mathcal{C}) > I(x_3, x_4|\mathcal{C}) > I(x_1, x_4|\mathcal{C}) > \\ I(x_1, x_3|\mathcal{C}) &> I(x_1, x_5|\mathcal{C}) > I(x_1, x_2|\mathcal{C}) > I(x_2, x_5|\mathcal{C}) > I(x_4, x_5|\mathcal{C}) \end{aligned}$$

Naučite polunaivan Bayesov klasifikator algoritmom 3-DB, skicirajte model kao Bayesovu mrežu te napišite izraz za zajedničku vjerojatnost.

- (d) Skicirajte funkciju log-izglednosti na skupu za učenje i skupu za provjeru u ovisnosti o broju k za model k -DB.

6. (4 boda) Bayesov klasifikator za kontinuirane ulaze.

- (a) Izgrađujemo Bayesov model za klasifikaciju primjera iz $\mathcal{X} = \mathbb{R}$ u tri klase. Učenjem na skupu primjera dobili smo sljedeće parametre modela: $P(\mathcal{C}_1) = 0.7$, $P(\mathcal{C}_2) = 0.2$, $\mu_1 = -2$, $\mu_2 = 0$, $\mu_3 = 1$, $\sigma_1^2 = 2$, $\sigma_2^2 = 1$, $\sigma_3^2 = 5$. Skicirajte funkcije gustoće vjerojatnosti $p(x|\mathcal{C}_j)$, $p(x)$ i $p(\mathcal{C}_j|x)$.
- (b) Kod multivarijatnog Bayesovog klasifikatora, izglednosti klasa definirane su gustoćom:

$$p(\mathbf{x}|\mathcal{C}_j) = \frac{1}{(2\pi)^{n/2}|\Sigma_j|^{1/2}} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_j)^T \Sigma_j^{-1}(\mathbf{x} - \boldsymbol{\mu}_j) \right\}.$$

Izvedite općeniti izraz za model $h(\mathbf{x}|\boldsymbol{\theta})$ s dijeljenom kovarijacijskom matricom.

- (c) Multivarijatni Bayesov klasifikator koristimo za predikciju mjesta prvog zapošljavanja studenata FER-a. Ulazne varijable su ocjene na dvadeset odabranih predmeta te duljina studija. Ciljne klase su: *industrija-hrv*, *industrija-ino*, *phd-hrv*, *phd-ino*. Koliki je ukupan broj parametara ovog modela uz pretpostavku (i) dijeljene kovarijacijske matrice te (ii) dijeljene i dijagonalne kovarijacijske matrice.

7. (4 boda) Linearan model regresije.

- (a) Empirijska pogreška linearnog modela regresije jest $E(\mathbf{w}|\mathcal{D}) = \frac{1}{2} \sum_{i=1}^N (y^{(i)} - \boldsymbol{\phi}(\mathbf{x}^{(i)})^T \mathbf{w})^2$. Pokažite da je minimizacija ovog izraza istovjetna maksimizaciji log-izglednosti $\ln \mathcal{L}(\mathbf{w}|\mathcal{D})$ (odnosno minimizaciji negativne log-izglednosti) uz pretpostavku normalno distribuiranog šuma $\mathcal{N}(h(\mathbf{x}|\mathbf{w}), \sigma^2)$.
- (b) Rješenje za vrijednosti težina koje minimizira regulariziranu pogrešku najmanjih kvadrata jest $\mathbf{w} = (\Phi^T \Phi + \lambda \mathbf{I})^{-1} \Phi^T \mathbf{y}$. Treniramo regresijski model za funkciju $\mathbb{R}^2 \rightarrow \mathbb{R}$. Raspoložemo primjerima $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 1), 4), ((1, 2), 1), ((2, 3), 2), ((4, 1), 5)\}$. Napišite izraz za \mathbf{w} i odredite dimenziju matrice koju treba invertirati ako koristimo funkciju preslikavanja $\boldsymbol{\phi}(\mathbf{x}) = (1, x_1, x_2, x_1 x_2, x_1^2, x_2^2)$.

8. (5 bodova) Regularizacija.

- (a) Napišite općenit izraz za L2-regulariziranu funkciju pogreške.
- (b) Regresijskim modelom aproksimiramo funkciju koja se ponaša slično jednoj periodi sinusne funkcije (no to nam nije unaprijed poznato). Raspoložemo s malo podataka koji sadrže razmjerno mnogo šuma. Neka je $\mathcal{H}_{d,\lambda}$ model polinoma d -tog stupnja s regularizacijskim faktorom λ . Iskušavamo četiri modela: $\mathcal{H}_{2,0}$, $\mathcal{H}_{2,100}$, $\mathcal{H}_{5,0}$, $\mathcal{H}_{5,100}$. Na dva odvojena crteža skicirajte (i) funkciju $h(x)$ za sva četiri modela te (ii) empirijsku pogrešku i pogrešku generalizacije za sva četiri modela.
- (c) Na jednom crtežu skicirajte empirijsku pogrešku te *regulariziranu* funkciju pogreške za model $\mathcal{H}_{d,\lambda}$ za $\lambda = 0$, $\lambda = 100$ i $\lambda = 1000$.
- (d) Na jednom crtežu skicirajte empirijsku pogrešku te *regulariziranu* funkciju pogreške za model $\mathcal{H}_{d,100}$ za slučajeve kada ima mnogo i kada ima malo šuma u podacima.
- (e) Odgovorite u jednoj rečenici: koja je probabilistička interpretacija L2-regularizacije?