

Strojno učenje – međuispit

UNIZG FER, ak. god. 2016./2017.

28. studenog 2016.

Ispit traje 180 minuta i nosi 35 bodova. Svaki zadatak rješavajte na zasebnoj stranici. Pišite uredno i čitko. Nemojte pretpostavljati da je nešto očito; Vaše znanje može se ocijeniti samo na temelju onog što napišete. Kod skica grafikona, označite osi, budite uredni i precizni te označite ekstremlje, ako postoje.

1. (6 bodova) Uvod i osnovni koncepti.

- (a) Formalno definirajte induktivnu pristranost i povežite vrste pristranosti s trima osnovnim komponentima algoritma strojnog učenja.
- (b) Raspoložemo modelom \mathcal{H}_α koji ima hiperparametar α koji određuje složenost (veći α daje složeniji model). Model je nelinearan, ali je funkcija pogreške nekonveksna i optimizacija može zaglaviti u lokalnom optimumu. Model treniramo dvama algoritmima, L_1 i L_2 , gdje je L_2 općenito bolji optimizacijski algoritam u smislu da češće nalazi globalni optimum od algoritma L_1 . Skicirajte pogreške učenja i ispitivanja kao funkcije od α za oba algoritma (četiri krivulje na jednom grafikonu).
- (c) Primjere $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), 1), (0, 1), 1), ((0, -1), 0)\}$ iz prostora $\mathcal{X} = \{-1, 0, 1\}^2$ želimo klasificirati modelom $h(x_1, x_2; \theta) = \mathbf{1}\{\theta_1 x_1 + \theta_2 x_2 \geq 0\}$, gdje $(\theta_1, \theta_2) \in \mathbb{R}^2$. Odredite $|VS_{\mathcal{H}, \mathcal{D}}|$ i $|\mathcal{H}|$.

2. (6 bodova) Regresija.

- (a) L2-regularizirana empirijska pogreška linearnog modela regresije jest $E(\mathbf{w}|\mathcal{D}) = \frac{1}{2} \sum_{i=1}^N (y^{(i)} - \mathbf{w}^T \mathbf{x}^{(i)})^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2$. Krenuvši od tog izraza, izvedite rješenje u matričnoj formi za težine \mathbf{w}^* koje minimiziraju regulariziranu pogrešku.
- (b) Model regresije treniramo na podatcima koji su generirani funkcijom $f(x) = 3 \cdot (x - 2)^2 + 1$. Koristimo funkciju preslikavanja $\phi(x) = (1, x, x^2)$. Skicirajte izokonture neregularizirane funkcije pogreške u ravni \mathbb{R}^2 koju definiraju parametri w_1 i w_2 i izokonture L2-regularizacijskog izraza. Ako je faktor λ odabran tako da se jednak značaj pridaje složenosti modela i minimizaciji pogreške, skicirajte (otprilike) vektor optimalnih težina (w_1^*, w_2^*) .
- (c) Linearnom višestrukom regresijom modeliramo ovisnost prihoda (zavisna varijabla) o dobi, godinama radnog staža i broju djece (nezavisne varijable). Na ovom primjeru ukratko objasnite problem multikolinearnosti i kako ga regularizacija rješava.

3. (4 boda) Linearni diskriminativni modeli.

- (a) Definirajte poopćeni linearni model i navedite varijante modela koje su (i) nelinearne u parametrima i (ii) nelinearne u granici između klasa.

- (b) Raspoložemo sljedećim primjerima za učenje

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-3, 1), 0), ((-3, 3), 0), ((1, 2), 1), ((2, 1), 1), ((1, -2), 2), ((2, -3), 2)\}.$$

Za klasifikaciju koristimo regresiju i shemu *jedan-naspram-ostali* (OVR). Definirajte dizajn-matricu i vektor oznaka \mathbf{y} za svaki od triju modela te skicirajte (otprilike) granice između klase u ulaznome prostoru.

- (c) Napišite funkciju pogreške perceptrona te navedite nedostatke perceptrona.

4. (6 bodova) Logistička regresija.

- (a) Izvedite pogrešku unakrsne entropije $E(\mathbf{w}|\mathcal{D})$ kao negativnu log-izglednost na skupu označenih primjera.
- (b) Izrazite gradijent funkcije pogreške unakrsne entropije $\nabla E(\mathbf{w}|\mathcal{D})$ te napišite pseudokôd algoritma gradijentnog spusta (*batch* i stohastičku izvedbu) za L2-regulariziranu logističku regresiju. Ukratko objasnite potrebu za linijskim pretraživanjem.
- (c) Nacrtajte graf funkcije gubitka $L(\mathbf{x}, y)$ u ovisnosti o točnosti klasifikacije za: (i) gubitak 0-1, (ii) kvadratni gubitak i (iii) logistički gubitak. Na temelju skice odgovorite zašto je logistički gubitak dobar za klasifikaciju, a kvadratni gubitak to nije.

5. (6 bodova) Stroj potpornih vektora.

- (a) Formulirajte, korak po korak, problem maksimalne margine i zatim izvedite, korak po korak, dualni kvadratni problem (tvrde) maksimalne margine s pripadnim uvjetima KKT.
- (b) Neka su potporni vektori linearnog SVM-a $\mathbf{x}^{(1)} = (-2, 3, 5, 5)$ i $\mathbf{x}^{(2)} = (6, 4, 3, 1)$. Prvi primjer je negativan, a drugi pozitivan. Dualni parametri su $\alpha_1 = 0.2$ i $\alpha_2 = 0.5$, a pomak je $w_0 = -2$. Napišite izraz za gubitak zglobnice i odredite gubitak hipoteze za primjer $\mathbf{x}^{(3)} = (1, 1, 1, 1)$, ako $y^{(3)} = -1$.
- (c) Koristimo SVM s Gaussovom jezgrenom funkcijom. Skicirajte pogrešku učenja i ispitnu pogrešku kao funkcije hiperparametra γ , i to za $C = \{1, 100, 1000\}$ (ukupno šest krivulja).

6. (7 bodova) Jezgrene i neparametarske metode.

- (a) Raspoložemo skupom primjera

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-1, -1), 0), ((0, 0), 0), ((3, -3), 1), ((-2, 1), 1), ((-4, 2), 1)\}.$$

Rabimo jezgreni stroj s dvije značajke i Gaussovom jezgrom $\kappa(\mathbf{x}, \mu_j) = \exp(-\gamma_j \|\mathbf{x} - \mu_j\|^2)$. Parametri jezgara su $\mu_1 = (0, 0)$, $\mu_2 = (-3, 3)$, $\gamma_1 = \gamma_2 = 1$. Skicirajte (otprilike) primjere u prostoru značajki i granicu koju biste dobili linearnom regresijom (nakon preslikavanja).

- (b) Raspoložemo s 1000 primjera za učenje u 100-dimenzijskome ulaznom prostoru. Odredite (i) broj parametara i broj hiperparametara jezgrenog stroja sa Gaussovom jezgrom koji preslikava u 10-dimenzijski prostor, (ii) interval mogućeg broja parametara i hiperparametara rijetkog jezgrenog stroja s Gaussovom jezgrom i (iii) interval broja (hiper)parametara za rijetki stroj s linearnom jezgrom.
- (c) Koristimo polinomijalnu jezgrenu funkciju $\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z} + 1)^2$. Pokažite da je za $n = 2$ jezgra κ Mercerova jezgra. Što to znači i zašto je to bitno?
- (d) Nabrojite prednosti inverznog oblikovanja.
- (e) Definirajte model k -NN i težinski k -NN. Kako biste odredili optimalnu vrijednost za k ?