


Prof.dr.sc. Bojana Dalbello Bašić

Fakultet elektrotehnike i računarstva
Zavod za elektroniku, mikroelektroniku, računalne i inteligentne sustave


www.zemris.fer.hr/~bojana
bojana.dalbelo@fer.hr

Strojno učenje

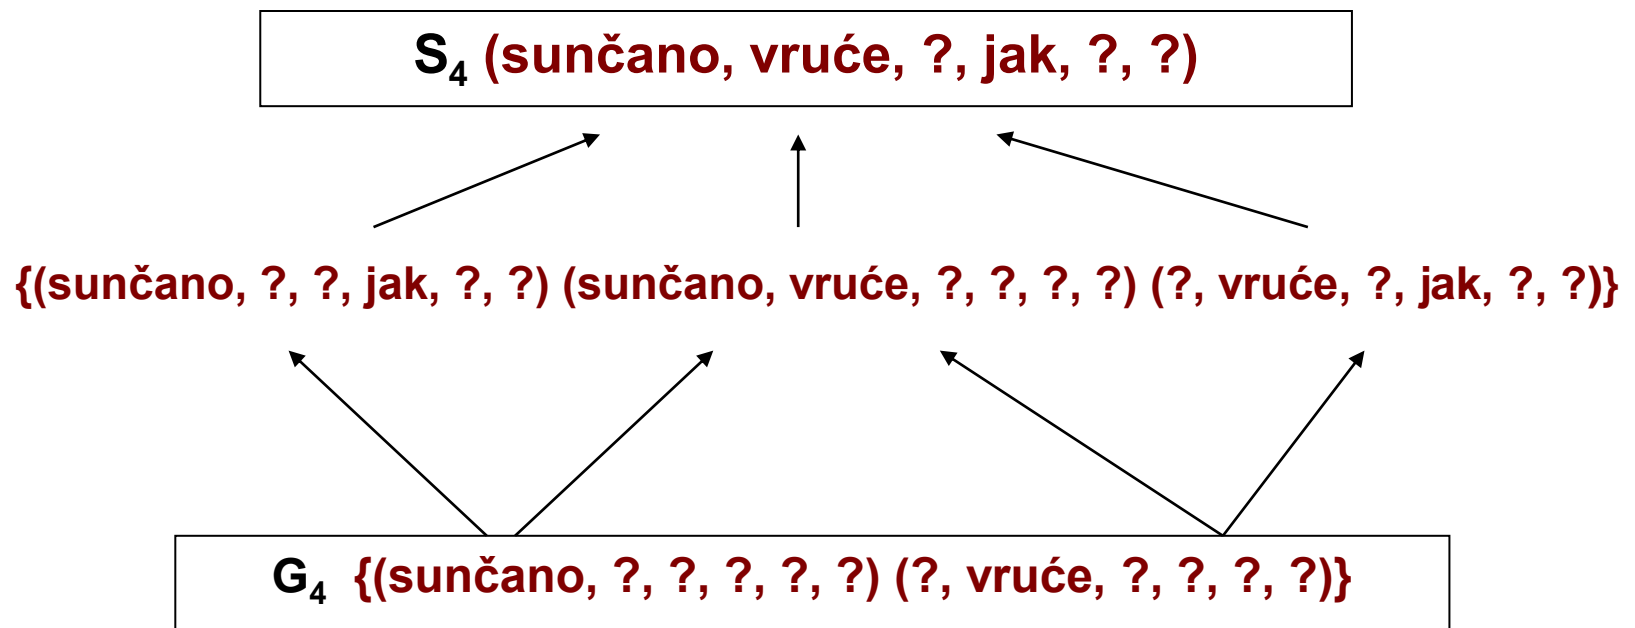
Učenje koncepata



- *Chapter 2*
Concept Learning and
the General-to-specific Ordering



- Konačni oblik prostora_inačica:



- Da li naučeni *prostor inačica* zavisi od redoslijeda predočavanja primjera?

PRIMJEDBE O *PROSTORU INAČICA* I ALGORITMU ELIMINACIJA_KANDIDATA

Da li algoritam ELIMINACIJA_KANDIDATA konvergira prema korektnoj hipotezi?

- Prostor inačica uz E_K algoritam konvergira prema pravoj hipotezi ako
 - Nema pogrešaka u primjerima za učenje
 - Postoji neka hipoteza u H koja korektno opisuje ciljni koncept

Ciljni koncept je točno naučen kada S i G konvergiraju prema jednoj identičnoj hipotezi!

PRIMJEDBE O *PROSTORU INAČICA* I ALGORITMU ELIMINACIJA_KANDIDATA

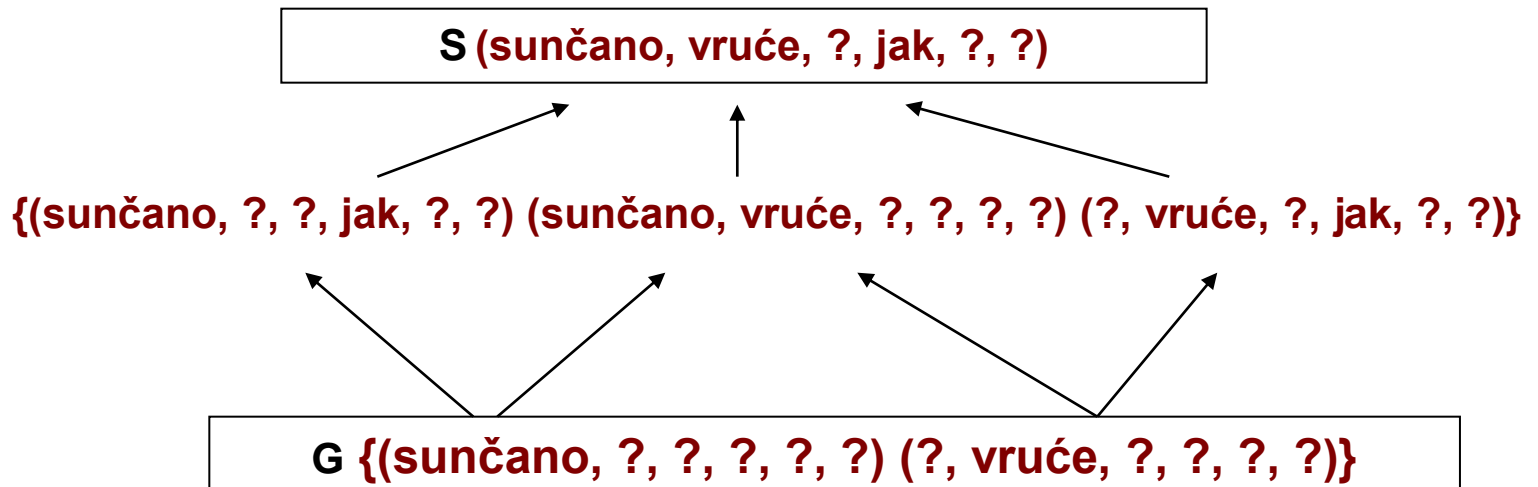
- Što se dešava kada se pozitivan primjer pogrešno deklarira kao negativan?
- Ispravni ciljni koncept se uklanja iz prostora inačica. (Uklanjaju se sve hipoteze nekonzistentne s primjerima za učenje).

Ako ima dovoljno primjera za učenje eventualno će S i G konvergirati prema praznom skupu – **NEMA HIPOTEZE KONZISTENTNE S PRIMJERIMA**

- Što ako se se ciljni koncept ne može opisati u odabranoj reprezentaciji hipoteze?
(konjunkcija -> disjunkcija atributa)

KOJI SLJEDEĆI PRIMJER ZA UČENJE UČENIK TREBA ZATRAŽITI?

- Do sada – primjere za učenje daje učitelj
- Što ako učenik može sam izabrati primjer za učenje i zatim dobiti informaciju iz vanjskog svijeta (učitelja, prirode) o korektnoj klasifikaciji izabranog primjera? → učenik postavlja **upit** (engl. *query*)

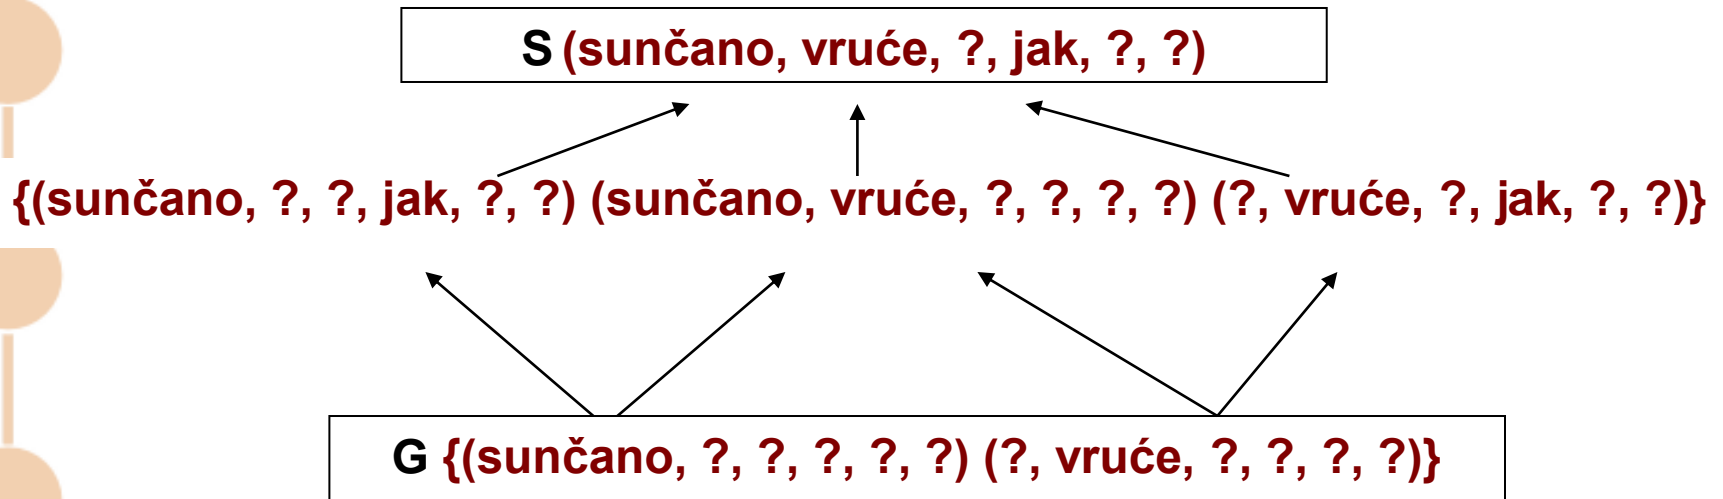


- Što bi bilo dobro pitanje u ovom slučaju?
- Što je dobra strategija upita uopće?

KOJI SLJEDEĆI PRIMJER ZA UČENJE UČENIK TREBA ZATRAŽITI?

- Učenik postavlja upit:

(sunčano, vruće, normalna, slab, topla, isto) ?




KOJI SLJEDEĆI PRIMJER ZA UČENJE UČENIK TREBA ZATRAŽITI?

- Učenik treba postavljati upit o primjeru koji dobro diskriminira između alternativnih hipoteza, tj. pozitivno klasificiran s nekim, a negativno s drugim hipotezama:
- Ako ga učitelj klasificira kao pozitivan, tada se **S** generalizira.
- Ako ga učitelj klasificira kao negativan, tada se **G** specijalizira.

**Prostor
inačica se
sužuje**

Idealan upit je onaj
koji zadovoljava $\frac{1}{2}$
hipoteza




Ciljni koncept može biti
ponađen u ? koraka

KOJI SLJEDEĆI PRIMJER ZA UČENJE UČENIK TREBA ZATRAŽITI?

- Učenik treba postavljati upit o primjeru koji dobro diskriminira između alternativnih hipoteza, tj. pozitivno klasificiran s nekim, a negativno s drugim hipotezama:
- Ako ga učitelj klasificira kao pozitivan, tada se **S** generalizira.
- Ako ga učitelj klasificira kao negativan, tada se **G** specijalizira.

**Prostor
inačica se
sužuje**

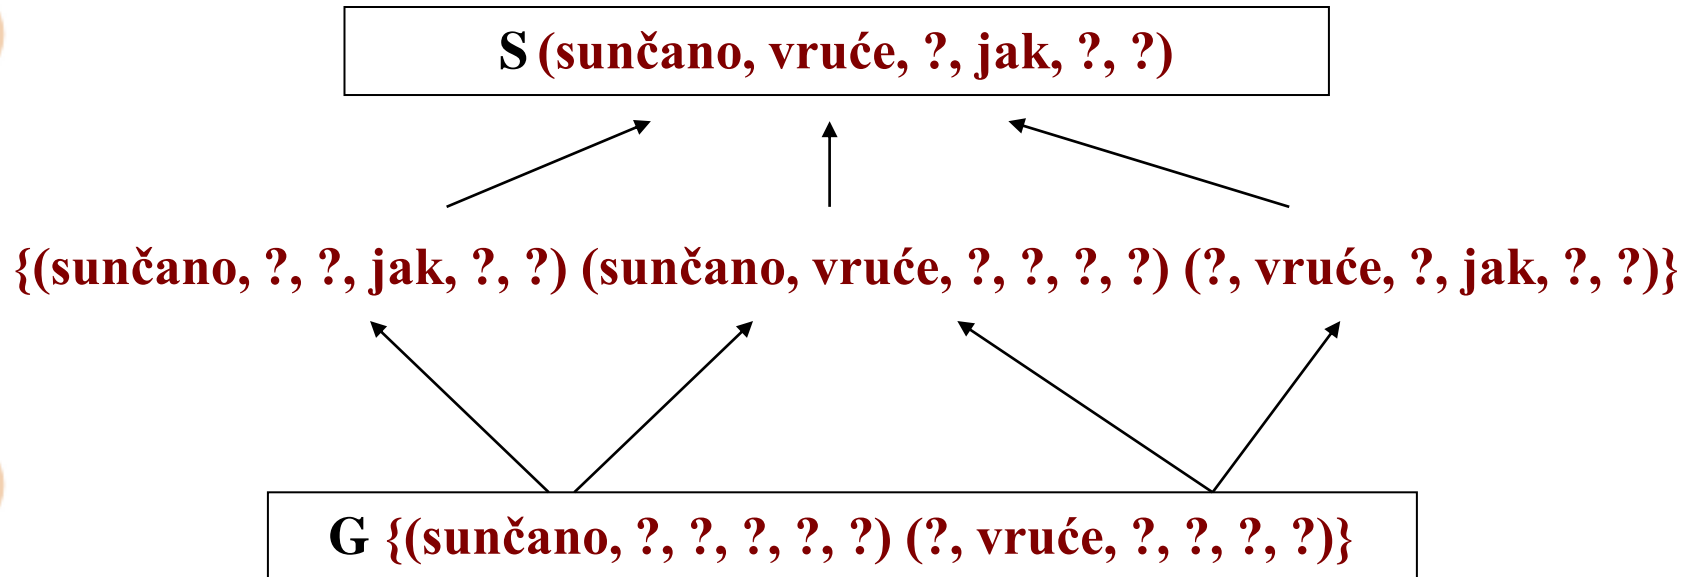
Idealan upit je onaj
koji zadovoljava $\frac{1}{2}$
hipoteza



Ciljni koncept može biti
ponađen u $\log_2|VS|$ koraka

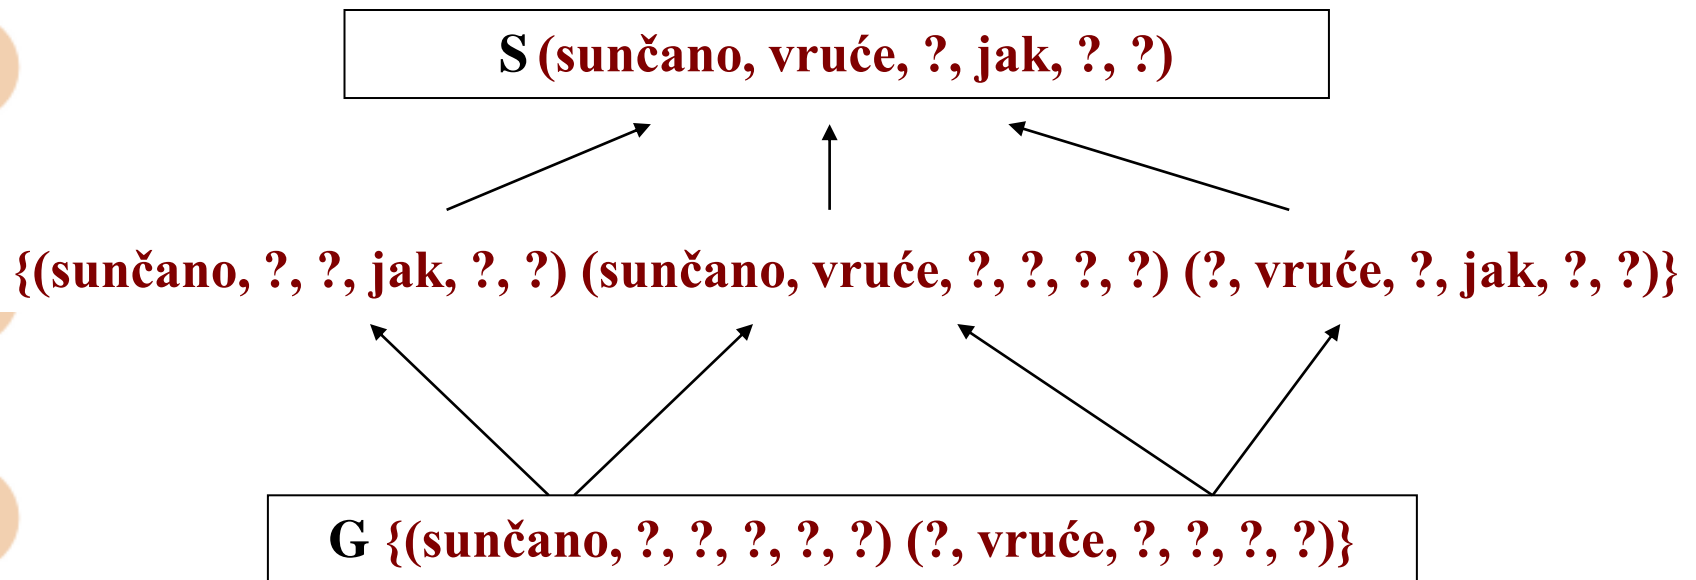
KAKO SE MOŽE KORISTITI PARCIJALNO NAUČEN KONCEPT?

- Samo četiri primjera za učenje u primjeru ***dan_za_sport***.
- Učenik treba klasificirati još neviđeni primjer
- *Prostor_inačica* sadrži višestruke hipoteze –
što to znači?



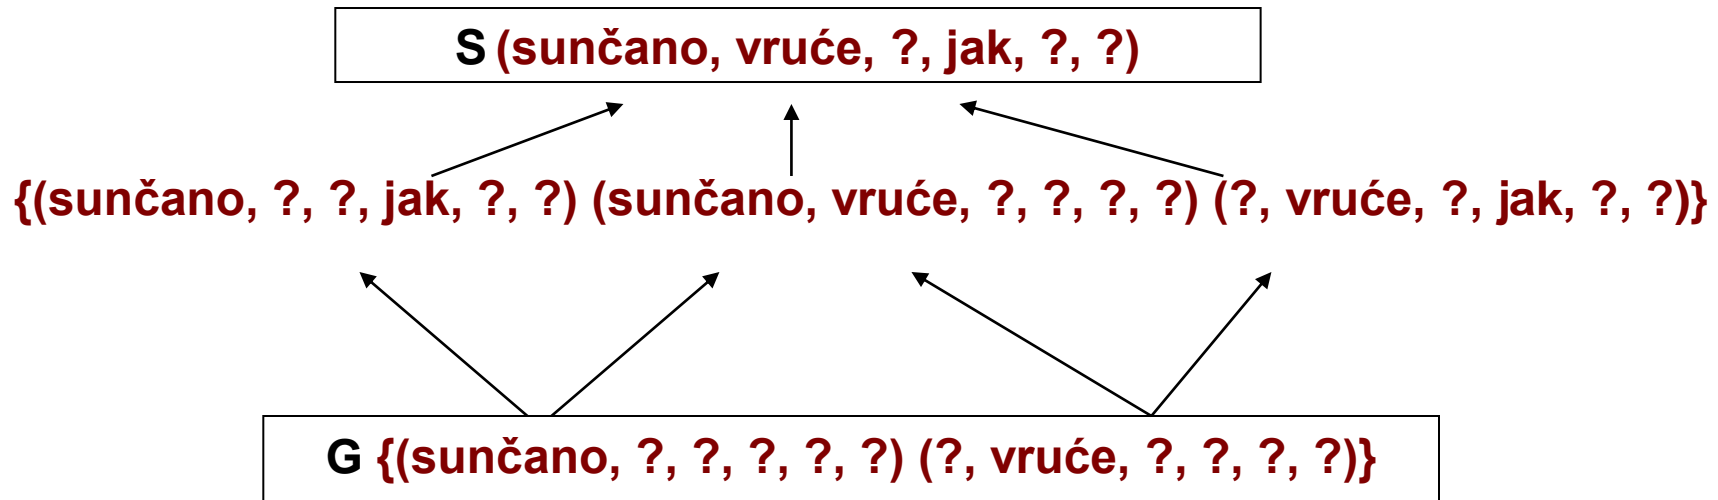
KAKO SE MOŽE KORISTITI PARCIJALNO NAUČEN KONCEPT?

- Ako ciljni koncept još nije naučen (višestruke hipoteze) da li učenik može klasificirati novi primjer s istim stupnjem pouzdanosti kao da je ciljni koncept jedinstveno identificiran?



KAKO SE MOŽE KORISTITI PARCIJALNO NAUČEN KONCEPT?

Primjer - dan	Naoblaka	Temperatura	Vlažnost	Vjetar	Voda	Prognoza	Dan za sport
A	sunčano	vruće	normalna	jak	hladna	promjena	?
B	kišno	hladno	normalna	slab	topla	isto	?
C	sunčano	vruće	normalna	slab	topla	isto	?
D	sunčano	hladno	normalna	jak	topla	isto	?



Da li je potrebno za svaku hipotezu provjeravati da pozitivno klasificira primjer A ili postupak možemo skratiti?

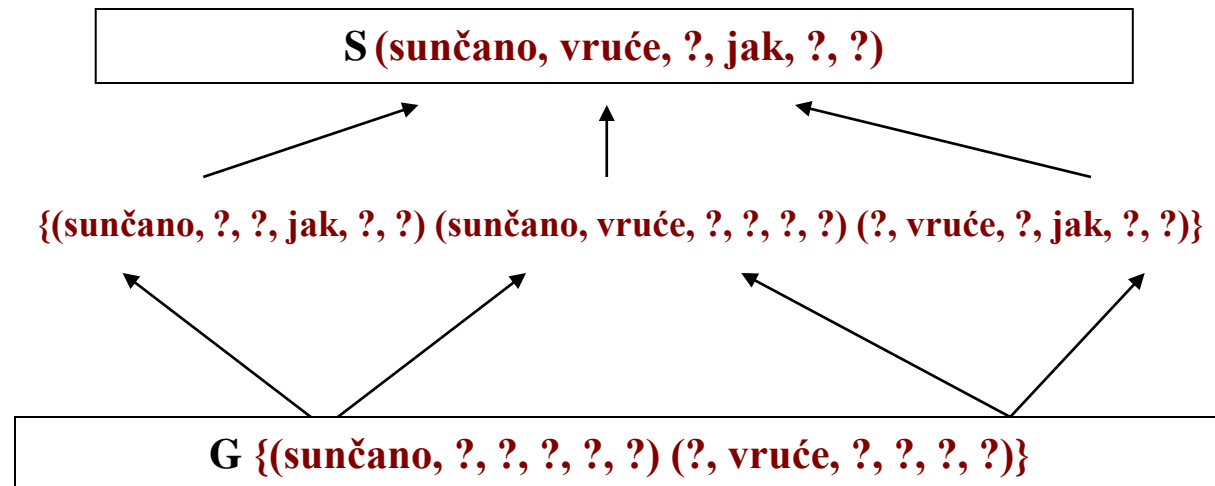
KAKO SE MOŽE KORISTITI PARCIJALNO NAUČEN KONCEPT?

<i>Primjer - dan</i>	<i>Naoblaka</i>	<i>Temperatura</i>	<i>Vlažnost</i>	<i>Vjetar</i>	<i>Voda</i>	<i>Prognoza</i>	<i>Dan za sport</i>
A	sunčano	vruće	normalna	jak	hladna	promjena	DA
B	kišno	hladno	normalna	slab	topla	isto	?
C	sunčano	vruće	normalna	slab	topla	isto	?
D	sunčano	hladno	normalna	jak	topla	isto	?

- **Primjer A** – pozitivno klasificiran sa svim hipotezama! – dakle učenik klasificira taj primjer kao pozitivan s istom pouzdanošću kao da se radi o jednoj hipotezi!
- Ako hipoteze iz *S* pozitivno klasificiraju *A* onda to vrijedi i za sve ostale hipoteze iz *prostora_inačica*

KAKO SE MOŽE KORISTITI PARCIJALNO NAUČEN KONCEPT?


Primjer - dan	Naoblaka	Temperatura	Vlažnost	Vjetar	Voda	Prognoza	Dan za sport
A	sunčano	vruće	normalna	jak	hladna	promjena	DA
B	kišno	hladno	normalna	slab	topla	isto	NE
C	sunčano	vruće	normalna	slab	topla	isto	?
D	sunčano	hladno	normalna	jak	topla	isto	?



Primjer B - negativno klasificiran sa svim hipotezama

KAKO SE MOŽE KORISTITI PARCIJALNO NAUČEN KONCEPT?


Primjer - dan	Naoblaka	Temperatura	Vlažnost	Vjetar	Voda	Prognoza	Dan za sport
A	sunčano	vruće	normalna	jak	hladna	promjena	DA
B	kišno	hladno	normalna	slab	topla	isto	NE
C	sunčano	vruće	normalna	slab	topla	isto	?
D	sunčano	hladno	normalna	jak	topla	isto	?



- Što je dovoljno provjeriti da smo sigurni da sve hipoteze klasificiraju primjer kao negativan?

KAKO SE MOŽE KORISTITI PARCIJALNO NAUČEN KONCEPT?

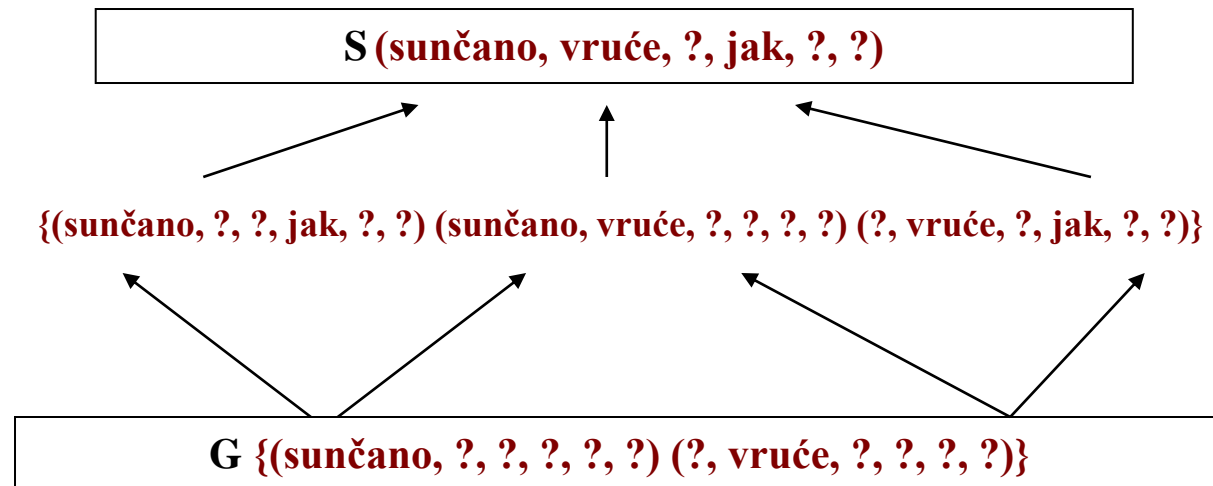
Primjer - dan	Naoblaka	Temperatura	Vlažnost	Vjetar	Voda	Prognoza	Dan za sport
A	sunčano	vruće	normalna	jak	hladna	promjena	DA
B	kišno	hladno	normalna	slab	topla	isto	NE
C	sunčano	vruće	normalna	slab	topla	isto	?
D	sunčano	hladno	normalna	jak	topla	isto	?



- Dovoljno je provjeriti da primjer ne zadovoljava sve članove skupa G

KAKO SE MOŽE KORISTITI PARCIJALNO NAUČEN KONCEPT?

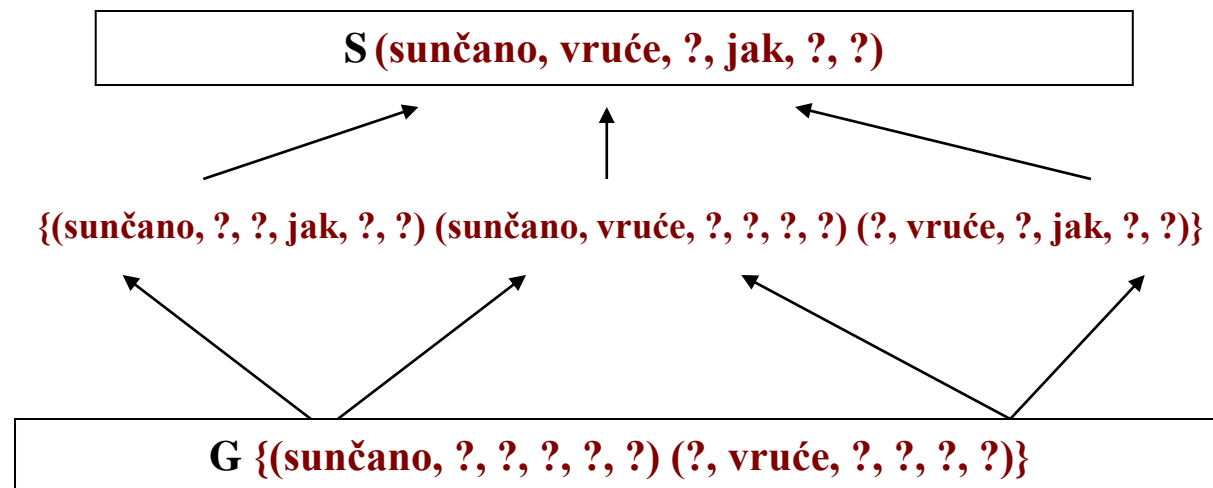
Primjer - dan	Naoblaka	Temperatura	Vlažnost	Vjetar	Voda	Prognoza	Dan za sport
A	sunčano	vruće	normalna	jak	hladna	promjena	DA
B	kišno	hladno	normalna	slab	topla	isto	NE
C	sunčano	vruće	normalna	slab	topla	isto	?
D	sunčano	hladno	normalna	jak	topla	isto	?



Primjer C – klasifikacija 50%-50%
(gore spomenuti primjer –idealni upit)

KAKO SE MOŽE KORISTITI PARCIJALNO NAUČEN KONCEPT?

Primjer - dan	Naoblaka	Temperatura	Vlažnost	Vjetar	Voda	Prognoza	Dan za sport
A	sunčano	vruće	normalna	jak	hladna	promjena	DA
B	kišno	hladno	normalna	slab	topla	isto	NE
C	sunčano	vruće	normalna	slab	topla	isto	50%-50%
D	sunčano	hladno	normalna	jak	topla	isto	2+ 4-



- Primjer D – 2 primjera pozitivno, 4 negativno → uvođenje vjerojatnosti. (pretpostavka : sve hipoteze jednako vjerojatne)

- Algoritam eliminacije kandidata konvergira prema stvarnom ciljnom konceptu ako:
 - primjeri za učenje iz D ne sadrže pogreške,
 - inicijalni prostor hipoteza H sadrži ciljni koncept.
- Pitanja:
 - Što ako ciljni koncept nije sadržan u H ?
 - Da li možemo izbjeći taj problem ako definiramo H koji sadrži sve moguće hipoteze?
 - Kako veličina H utječe na sposobnost algoritma da generalizira na još ne predložene primjere (problem ekspresivnosti)?
 - Kako veličina H utječe na veličinu skupa primjera za učenje D ?

- Algoritam eliminacije kandidata konvergira prema stvarnom ciljnom konceptu ako:
 - primjeri za učenje iz D ne sadrže pogreške,
 - inicijalni prostor hipoteza H sadrži ciljni koncept.
- Pitanja:
 - **Što ako ciljni koncept nije sadržan u H ?**
 - Da li možemo izbjeći taj problem ako definiramo H koji sadrži sve moguće hipoteze?
 - Kako veličina H utječe na sposobnost algoritma da generalizira na još ne predložene primjere (problem ekspresivnosti)?
 - Kako veličina H utječe na veličinu skupa primjera za učenje D ?

PRISTRAN PROSTOR HIPOTEZA

- Da bi bili sigurni da je ciljni koncept u **H** –proširujemo prostor hipoteza **H**
- Primjer: ***dan_za sport***
- Restrikcija je bila: hipoteza = **konjunkcija** atributa!
- Ako je ciljni koncept jednostavna **disjunkcija** poput:
- **Vrijeme = sunčano** ili **Vrijeme = oblačno** → ciljni koncept nije sadržan u **H**!
- Skup za učenje:

<i>Primjer - dan</i>	<i>Naoblaka</i>	<i>Temperat ura</i>	<i>Vlažnost</i>	<i>Vjetar</i>	<i>Voda</i>	<i>Prognoza</i>	<i>Dan za sport</i>
1	sunčano	vruće	normalna	jak	hladna	promjena	DA
2	oblačno	vruće	normalna	jak	hladna	promjena	DA
3	kišno	vruće	normalna	jak	hladna	promjena	NE

- Algoritam daje rezultat: *Nema hipoteze u obliku konjunkcije atributa konzistentne s podacima!*

Objasni!



PRISTRAN PROSTOR HIPOTEZA

- Nakon prva dva predočena pozitivna primjera:
 S_2 (?, vruće, normalna, jak, hladna, promjena)
- Iako je to maksimalno specifična hipoteza konzistentna s pozitivnim primjerima ona je preopćenita pa nekorektno klasificira treći primjer! Kakav rezultat daje algoritam E_K ?
- Ovakav učenik je **pristran** jer razmatra samo konjuktivne hipoteze !
- Potreban je **H** s većom moći izražavanja!

- Pitanja:
 - Što ako ciljni koncept nije sadržan u H ?
 - **Da li možemo izbjeći taj problem ako definiramo H koji sadrži sve moguće hipoteze?**
 - Kako veličina H utječe na sposobnost algoritma da generalizira na još ne predložene primjere (problem ekspresivnosti)?
 - Kako veličina H utječe na veličinu skupa primjera za učenje D ?

- **Pristup:** treba osigurati da **H** može predstaviti svaki mogući koncept koji se može naučiti tj. **svaki mogući podskup skupa primjera X.**

- Primjer: ***dan_za sport*** . Veličina prostora primjera X je definirana sa:

$$3*2*2*2*2 = 96$$

- **Koliko mogućih koncepata može biti definirano na takvom skupu primjera X, ako svaki mogući podskup skupa X može biti koncept?**

- Koliko mogućih koncepata može biti definirano na takvom skupu primjera X ?
- Odgovor: koliki je partitivni skup od X tj. $2^{|X|}$, što u ovom slučaju iznosi $2^{96} \approx 10^{28}$!
- Za prostor H , kako smo ga definirali (konjunkcija atributa), moguće je prikazati **samo 973 hipoteza** → vrlo pristran prostor hipoteza!
- Definiramo **novi prostor hipoteza X** koji sadrži partitivni skup od X , gdje je $|X| \approx 10^{28}$

- Jedan od načina definiranja takvog novog prostora hipoteza H' je dozvoliti operacije konjunkcije, disjunkcije i negacije skupa hipoteza H .
- Ciljni koncept Vrijeme = *sunčano* ili Vrijeme = *oblačno* može se prikazati kao:
 $(\text{sunčano}, ?, ?, ?, ?, ?) \vee (\text{oblačno}, ?, ?, ?, ?, ?)$
- Sa takvim prostorom hipoteza H' nestaje problem nemogućnosti predstavljanja ciljnog koncepta

NOVI PROBLEM → Algoritam je nesposoban generalizirati iznad primjera za učenje!

- Pitanja:
 - Što ako ciljni koncept nije sadržan u H ?
 - Da li možemo izbjeći taj problem ako definiramo H koji sadrži sve moguće hipoteze?
 - **Kako veličina H utječe na sposobnost algoritma da generalizira na još ne predložene primjere (problem ekspresivnosti)?**
 - **Kako veličina H utječe na veličinu skupa primjera za učenje D ?**

Primjer:

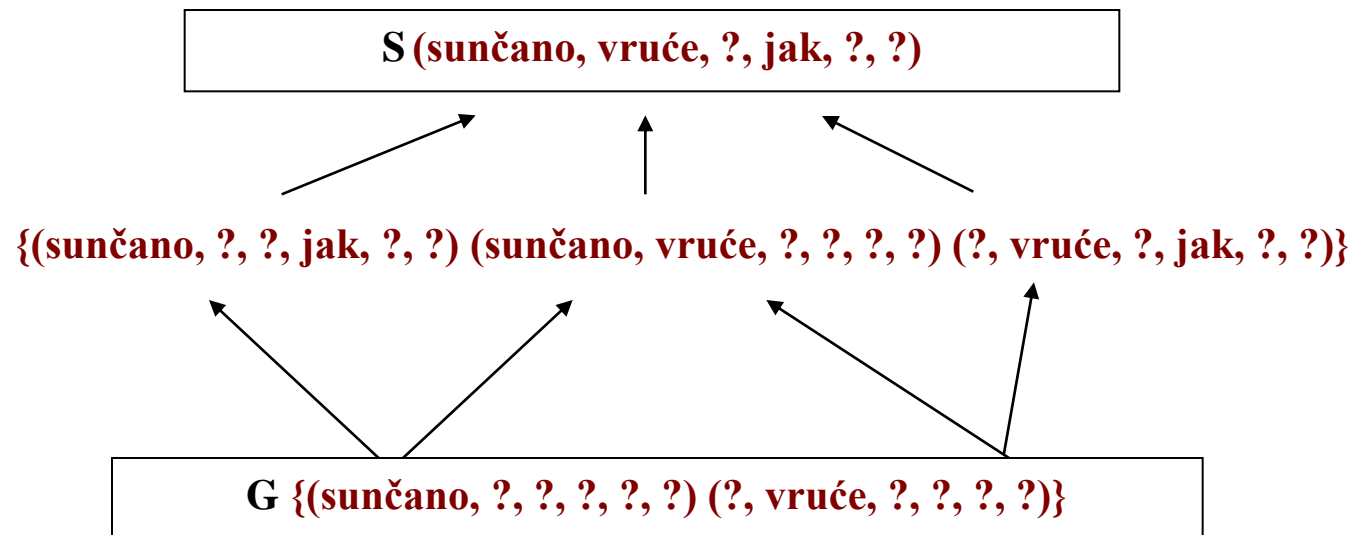
- Nakon tri pozitivna primjera (x_1, x_2, x_3) i dva negativna primjera (x_4, x_5)

$$\mathbf{S} \{ (x_1 \vee x_2 \vee x_3) \} \text{ i } \mathbf{G} \{ \neg(x_4 \vee x_5) \}$$

U takvoj reprezentaciji **S** će uvijek biti disjunkcija pozitivnih primjera za učenje, a **G** negacija disjunkcije negativnih primjera za učenje.

- Jedini primjeri koji su nedvosmisleno klasificirani sa **S** i **G** jesu primjeri za učenje.
- Da bi konvergirali jedinstvenom ciljnom konceptu svaki primjer iz **X** mora biti predložen kao primjer za učenje, tj. **X=D!**

- Da li bi mogli doskočiti tom problemu ($X=D$) tako da koristimo djelomično naučen prostor inačica (koji još nismo sveli na jedinstven ciljni koncept) i ispitujemo broj pozitivnih, odnosno negativnih klasifikacija ?
- Sjetimo se primjera **dan_za_sport**:



NEPRISTRAN UČENIK

<i>Primjer - dan</i>	<i>Naoblaka</i>	<i>Temperat ura</i>	<i>Vlažnost</i>	<i>Vjetar</i>	<i>Voda</i>	<i>Prognoza</i>	<i>Dan za sport</i>
A	sunčano	vruće	normalna	jak	hladna	promjena	DA
B	kišno	hladno	normalna	slab	topla	isto	NE
C	sunčano	vruće	normalna	slab	topla	isto	50%- 50%
D	sunčano	hladno	normalna	jak	topla	isto	2+ 4-

- Primjer A – pozitivno klasificiran sa svim hipotezama! – dakle učenik klasificira taj primjer kao pozitivan s istom pouzdanošću kao da se radi o jednoj hipotezi!
- Primjer C – klasifikacija 50%-50%
- Primjer D – 2 primjera pozitivno, 4 negativno

- Ali, u slučaju kada je $H = P(X)$, jedini primjeri koji će dobiti nedvosmislenu klasifikaciju su prethodno predloženi pozitivni i negativni primjeri.
- Za sve ostale primjere vrijedi: svaki novi primjer bit će klasificiran pozitivno sa točno pola hipoteza u prostoru inačica, i negativno sa drugom polovinom hipoteza u tom prostoru

Zašto?

- Svaki novi primjer bit će klasificiran pozitivno sa točno pola hipoteza u prostoru inačica, i negativno sa drugom polovinom hipoteza u tom prostoru

Zašto?

- **$H = P(X)$**

Za svaki novi primjer x , i hipotezu h iz prostora inačica koja pokriva x , postoji hipoteza h' u partitivnom skupu $P(X)$ koja je identična sa h osim što negativno klasificira primjer x .

Naravno, ako je h u VS, tada je i h' jer se obje slažu s do sada predloženim primjerima

UZALUDNOST UČENJA BEZ PRISTRANOSTI

- Osnovno pravilo induktivnog zaključivanja:

Učenik koji ne čini a priori pretpostavke o ciljnom konceptu

nema ni razumne pristranosti pri klasificiranju još neviđenih primjera!

UZALUDNOST UČENJA BEZ PRISTRANOSTI

- Jedini razlog zbog kojeg je algoritam *eliminacije kandidata* mogao **generalizirati** iznad predočenih primjera je izvorna formulacija zadatke ***dan_za_sport*** koja je bila **pristrana** zbog implicitne pretpostavke da se ciljni koncept može predstaviti kao konjunkcija atributa!
- U slučajevima u kojima je ta pretpostavka točna i ako su primjeri za učenje ispravni, klasifikacija novih primjera će biti korektna

UZALUDNOST UČENJA BEZ PRISTRANOSTI

- Kako induktivno učenje zahtijeva neke *a priori* pretpostavke, metode učenja razlikovat ćemo po toj a priori pretpostavki ili **induktivnoj pristranosti** na koju se oslanjaju
- Na temelju čega učenik generalizira iznad predloženih podataka da bi klasificirao nove primjere za učenje?

UZALUDNOST UČENJA BEZ PRISTRANOSTI

- L - proizvoljan algoritam učenja
- $D_c = \{(x, c(x))\}$ – skup podataka za učenje
- c – ciljni koncept
- Nakon učenja L treba klasificirati novi primjer x_i .
- $L(x_i, D_c)$ označava klasifikaciju (+ ili -) od x_i koju pridjeljuje L nakon što mu je predodčen D_c .
- **Induktivni korak zaključivanja:**

$$(D_c \wedge x_i) \succ L(x_i, D_c)$$

UZALUDNOST UČENJA BEZ PRISTRANOSTI

- Na primjer, ako je L algoritam eliminacije kandidata, D_c skup primjera za učenje iz tablice primjera ***dan_za_sport***, a x_i primjer:

<i>Primjer - dan</i>	<i>Naoblaka</i>	<i>Temperat ura</i>	<i>Vlažnost</i>	<i>Vjetar</i>	<i>Voda</i>	<i>Prognoza</i>	<i>Dan za sport</i>
A	sunčano	vruće	normalna	jak	hladna	promjena	?

- Tada je induktivni zaključak u tom slučaju:
 $L(x_i, D_c) = (\mathbf{dan_za_sport} = DA)$

UZALUDNOST UČENJA BEZ PRISTRANOSTI

- Na primjer, ako je L algoritam eliminacije kandidata, D_c skup primjera za učenje iz tablice primjera ***dan_za_sport***, a x_i primjer:

Primjer - dan	Naoblaka	Temperat ura	Vlažnost	Vjetar	Voda	Prognoza	<i>Dan za sport</i>
A	sunčano	vruće	normalna	jak	hladna	promjena	DA

- S obzirom da je L je induktivan algoritam, rezultat $L(x_i, D_c)$ neće biti općenito korektan, tj.
klasifikacija $L(x_i, D_c)$ ne mora deduktivno slijediti iz primjera za učenje i opisa novog primjera
- Pitanje: Koje dodatne pretpostavke trebamo dodati na $x_i \wedge D_c$ tako da $L(x_i, D_c)$ slijedi deduktivno?

UZALUDNOST UČENJA BEZ PRISTRANOSTI

- Definirat ćemo induktivnu pristranost učenika kao skup dodatnih pretpostavki **B**, dovoljnih da potvrde **induktivni zaključak kao deduktivni** točnije, induktivna pristranost od **L** je skup pretpostavki **B**, takvih da za svaki novi primjer x_i vrijedi:

$$(B \wedge D_c \wedge x_i) \vdash L(x_i, D_c),$$

gdje $x \vdash y$ znači da **y** slijedi deduktivno iz **x**
(y je dokaziv iz x)

UZALUDNOST UČENJA BEZ PRISTRANOSTI

Definicija

Neka je L algoritam za učenje koncepata za skup primjera X . Neka je c proizvoljni koncept definiran na X , i neka je $D = \{(x, c(x))\}$ proizvoljan skup primjera za učenje koncepta c . Neka $L(x_i, D_c)$ označava klasifikaciju pridruženu primjeru x_i algoritmom L koji je naučen na skupu D_c .

Induktivna pristranost od L je bilo koji skup minimalnih pretpostavki B takvih da za bilo koji ciljni koncept c i odgovarajući skup primjera za učenje D_c vrijedi:

$$(\forall x_i \in X)[(B \wedge D_c \wedge x_i) \vdash L(x_i, D_c),]$$

UZALUDNOST UČENJA BEZ PRISTRANOSTI

- Što je induktivna pristranost algoritma **eliminacije kandidata**?
- Prethodno je potrebno precizno definirati klasifikaciju $L(x_i, D_c)$ za algoritam *eliminacije kandidata* L . Algoritam će na temelju primjera najprije naći VS_{HD} , a zatim će klasificirati novi primjer x_i .

Dodatna pretpostavka:

Primjer x_i će biti klasificiran samo u slučaju uniformne klasifikacije svih hipoteza iz prostora inačica (sve pozitivne ili sve negativne) u protivnom, L neće klasificirati novi primjer x_i

UZALUDNOST UČENJA BEZ PRISTRANOSTI

Induktivna pristranost algoritma eliminacije kandidata:
Ciljni koncept c je sadržan u prostoru hipoteza H !

- Uz tu pretpostavku svaki induktivni zaključak o klasifikaciji na temelju algoritma *eliminacije kandidata* može biti potvrđen deduktivno.

UZALUDNOST UČENJA BEZ PRISTRANOSTI

Objašnjenje zašto klasifikacija $L(x_i, D_c)$ slijedi deduktivno iz $B = \{c \in H\}$, skupa s podacima D_c i primjerom x_i

1. Ako je $c \in H$ tada je i $c \in VS_{H,D_c}$. To slijedi iz definicije prostora VS_{H,D_c} (kao skupa svih onih hipoteza iz H koje su konzistentne s D_c) i skupa $D_c = \{(x, c(x))\}$ (kao skupa podataka za učenje konzistentnih sa ciljnom hipotezom c)
2. Definirali smo klasifikaciju $L(x_i, D_c)$ kao nedvosmisleni klasifikaciju svih hipoteza u prostoru $VS_{H,D}$. Dakle, kada algoritam L predoči klasifikaciju $L(x_i, D_c)$, tu su klasifikaciju odredili jednoglasno svi članovi prostora $VS_{H,D}$ pa onda i c jer se c nalazi u $VS_{H,D}$

$$c(x_i) = L(x_i, D_c)$$

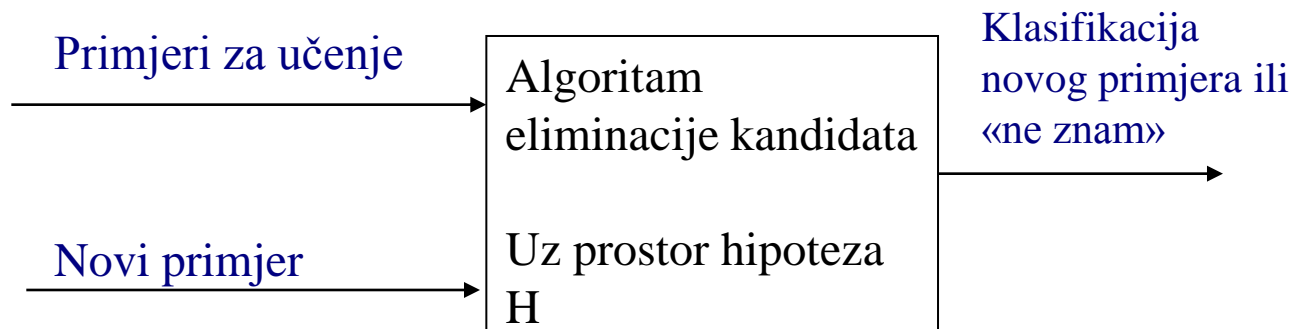
Induktivna pristranost algoritma eliminacije kandidata: Ciljni koncept c je sadržan u prostoru hipoteza H

UZALUDNOST UČENJA BEZ PRISTRANOSTI

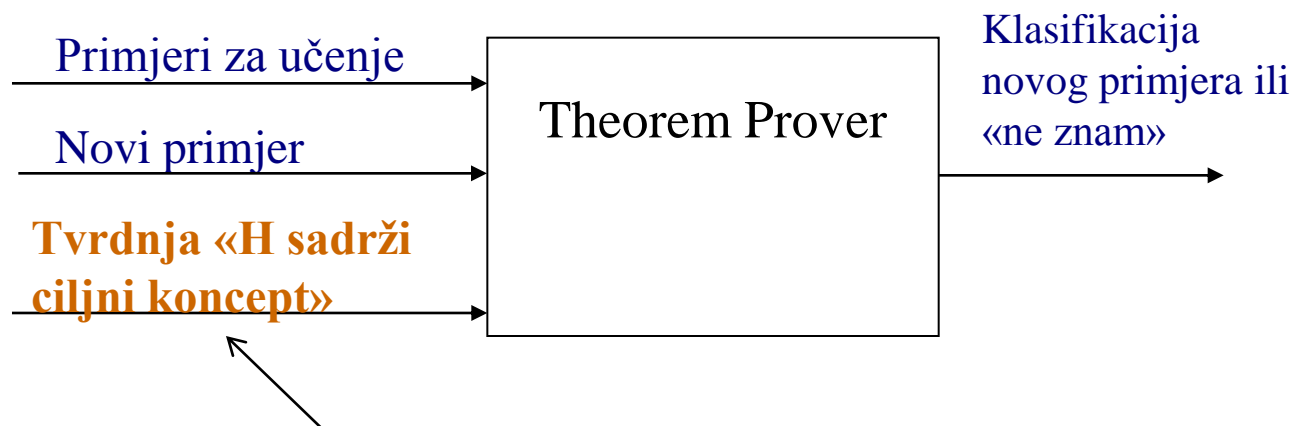
- Opisivanje induktivnih sustava sa njihovom induktivnom pristranošću, dozvoljava njegovo modeliranje sa ekvivalentnim deduktivnim sustavom
- Sljedeća dva sustava proizvode iste izlaze za svaki mogući skup D i svaki mogući primjer x

UZALUDNOST UČENJA BEZ PRISTRANOSTI

Induktivni sustav



Ekvivalentni deduktivni sustav



Induktivna pristranost
uključena eksplicitno

UZALUDNOST UČENJA BEZ PRISTRANOSTI

- Prednost pogleda na induktivne sustave preko njihove induktivne pristranosti su:
 - Neproceduralno sredstvo kojim se opisuje način njihove generalizacije iznad predočenih primjera
 - Usporedbe različitih sustava učenje na temelju njihove induktivne pristranosti

UZALUDNOST UČENJA BEZ PRISTRANOSTI

- Primjeri tri algoritma poredanih od najslabije do najjače induktivne pristranosti koju uključuju:
 1. **ROTE-LEARNER** – uči pohranjujući svaki predočeni primjer u memoriju. Novi primjer se klasificira u skladu kako je pohranjen u memoriji, a ako ga nema, sustav ga ne klasificira.
 2. **ALGORITAM ELIMINACIJE KANDIDATA** – Novi primjer se klasificira samo ako su svi članovi prostora VS suglasni, inače se ne klasificira.
 3. **NADI-S** algoritam, nalazi najspecifičniju hipotezu konzistentnu s pozitivnim primjerima. Tada tu hipotezu koristi da bi klasificirao nove primjere

UZALUDNOST UČENJA BEZ PRISTRANOSTI

1. ROTE LEARNER – **nema induktivne pristranosti**, zaključak je deduktivan bez dodatnih pretpostavki
2. ELIMINACIJA KANDIDATA **ima induktivnu pristranost** (koju?) i zato je u stanju klasificirati neke primjere koji ROTE-LEARNER nije u stanju. Ispravnost te klasifikacije zavisi o korektnosti induktivne pretpostavke
3. NAĐI-S osim iste induktivne pristranosti koju ima ALGORITAM ELIMINACIJE KANDIDATA ima i **dodatnu pristranost da su svi drugi primjeri negativni** osim ako to nije suprotno postavljeno drugim znanjem.

UZALUDNOST UČENJA BEZ PRISTRANOSTI

- I druge induktivne metode se mogu klasificirati prema induktivnoj pristranosti.
- Neke su pretpostavke slabe («preferiraju se specifičnije hipoteze od općenitijih» - samo rangira hipoteze) dok su druge vrlo kategoričke («c je u H»).
- Neke su pretpostavke **implicitne** (kao u ovim algoritmima), a neke su vrlo **eksplicitne** i formulirane kao pretpostavke kojima učenik barata.

- *Chapter 2*
Concept Learning and the General-to-specific Ordering

