


Prof.dr.sc. Bojana Dalbello Bašić


Fakultet elektrotehnike i računarstva  
Zavod za elektroniku, mikroelektroniku, računalne i inteligentne sustave

[www.zemris.fer.hr/~bojana](http://www.zemris.fer.hr/~bojana)  
[bojana.dalbello@fer.hr](mailto:bojana.dalbello@fer.hr)

## Evaluacija hipoteza




- *Chapter 5*  
Evaluacija hipoteza



- Postupak učenja provodi se najčešće na uzorku ograničene veličine.
  - Koliko je precizna i pouzdana naučena hipoteza?
- Važnost evaluacije performansi naučene hipoteze:
  - zbog buduće uporabe hipoteze
  - evaluacija hipoteza komponenta mnogih metoda za učenje (npr. podrezivanje stabla odluke)

# Procjena pouzdanosti hipoteze

- Zanima nas:
  - točnost (preciznost) klasificiranja budućih primjera
  - pouzdanost te klasifikacije.
- Skup svih mogućih primjera  $\mathbf{X}$  na kojem je definiran ciljni koncept  $f$ :



- Različiti primjeri imaju različitu vjerojatnost pojavljivanja.

- Zadaća učenja: naučiti ciljnu funkciju  $f: X \rightarrow \{0, 1\}$ , pretražujući prostor hipoteza  $H$
- $X$  - skup svih primjera
- **Primjeri za učenje:**
  - Elementi iz  $X$ , izabrani slučajno, u skladu s distribucijom  $D$ , kojima je pridružena vrijednost ciljnog koncepta  $f(x)$ .

- Za danu hipotezu  $h$  i skup primjera od  $n$  elemenata, izvučen slučajno iz skupa  $X$ , **koja je najbolja procjena točnosti hipoteze  $h$**  za nove primjere izvučene iz skupa  $X$  na temelju distribucije vjerojatnosti  $D$ ?
- 
- Kolika je **vjerojatnost pogreške u toj procjeni točnosti?**

# Pogreška uzorka i stvarna pogreška

- Proporcija (stopa) pogreške hipoteze nad primjerima za učenje – **pogreška uzorka** (*engl. sample error*).
- Proporcija (stopa) pogreške hipoteze nad cjelom populacijom s distribucijom  $D$  – **stvarna pogreška** (*engl. true error*).
- Pretpostavimo da imamo neku hipotezu  $h$  (npr. stablo odluke).
- Slučajno odaberemo  $n$  primjera iz  $D$  – to je slučajan uzorak  $S$ . Na tom uzorku odredimo stopu pogreške hipoteze  $h$  tj. proporciju krivo klasificiranih primjera (stopa = broj krivo klasificiranih primjera/ $n$ ). Označimo tu stopu pogreške na uzorku s  **$\text{error}_S(h)$**  i nazovimo je **pogreška uzorka**.

- *Definicija*
- **Pogreška uzorka**  $\text{error}_S(h)$  hipoteze  $h$  u odnosu na ciljnu funkciju  $f$  i uzorak  $S$  jest

$$\text{error}_S(h) = \frac{1}{n} \sum_{x \in S} \delta(f(x), h(x)) ,$$

gdje je  $n$  broj elemenata u uzorku  $S$ ,  
 $\delta(f(x), h(x)) = 1$  ako  $f(x) \neq h(x)$ ,  
0 inače.

- Stvarna pogreška hipoteze  $h$  jest vjerojatnost da će  $h$  krivo klasificirati jedan slučajno izvučen primjer iz distribucije  $D$ .



- Stvarna pogreška hipoteze  $h$  jest vjerojatnost da će  $h$  krivo klasificirati jedan slučajno izvučen primjer iz distribucije  $D$ .

## *Definicija*

- **Stvarna pogreška** ( $\text{error}_D(h)$ ) hipoteze  $h$ , u odnosu na ciljnu funkciju  $f$  i distribuciju  $D$  jest vjerojatnost da će  $h$  krivo klasificirati jedan slučajno izvučen primjer iz distribucije  $D$ .


$$\text{error}_D(h) = P_{x \in D}[f(x) \neq h(x)].$$

- Želimo znati stvarnu pogrešku.
- Na raspolaganju nam je samo pogreška uzorka.

# Koliko je $\text{error}_S(h)$ dobra procjena $\text{error}_D(h)$ ?

- Očekujemo da se pogreška uzorka  **$\text{error}_{S_i}(h)$**  razlikuje za različite uzorke  $S_i$  od  $n$  elemenata.
- Slučajni pokus je pokus čiji ishod nije jednoznačno određen uvjetima eksperimenta.
- U ovom slučaju slučajni pokus je izvlačenje slučajnog uzorka  $S_i$  od  $n$  primjera.

Slučajno  
odabrani  
uzorci  $S_i$  iz  
skupa svih  
primjera  $X$



vrijednosti  
slučajne  
variable

# Koliko je $\text{error}_S(h)$ dobra procjena $\text{error}_D(h)$ ?

- Svakom takvom ishodu slučajnog pokusa tj. jednom uzroku  $S_i$  od  $n$  elemenata pridružimo proporciju krivo klasificiranih primjera neke hipoteze  $h$ .
- **$\text{error}_{S_i}(h)$**  je vrijednost pridružena  $i$ -tom slučajnom pokusu – tj. **slučajna varijabla**.
- Pojednostavljeno možemo slučajnu varijablu predstaviti kao funkciju koja pridružuje neku numeričku vrijednost (u našem slučaju  $\text{error}_{S_3}(h)$ ) ishodu slučajnog pokusa (u našem primjeru slučajno odabrani uzorci od  $n$  primjera).

- Primjer su vjerojatnosti koje se pojavljuju u  $n$  uzastopnih međusobno nezavisnih **bacanja novčića**.
- Označimo sa  $\pi$  vjerojatnost novčić padne na glavu.
- Napravimo pokus od  $n$  bacanja novčića i pretpostavimo da je glava pala  $r$  puta. Razumna procjena za  $\pi$  je omjer  $r/n$ .
- Bacanje novčića jest slučajan pokus – tj. pokus čiji ishod nije jednoznačno određen uvjetima pokusa.
- Zbog toga, ako ponovimo pokus od  $n$  bacanja novčića očekujemo neku drugu procjenu  $r_1/n$  za pravu vrijednost vjerojatnosti  $\pi$ .
- Binomna distribucija opisuje vjerojatnost dobivanja točno  $r$  glava u nizu od  $n$  bacanja novčića, gdje  $r$  može biti bilo koja vrijednost od 0 do  $n$ .

- Procjena vjerojatnosti  $\pi$  pada glave kod slučajnog pokusa bacanja novčića na temelju pokusa od  $n$  bacanja novčića ekvivalentna je procjeni prave pogreške  **$\text{error}_D(\mathbf{h})$**  neke dane hipoteze  $h$  (npr. stabla odluke) na temelju slučajnog uzorka od  $n$  primjera iz  $D$ .
- Jedno bacanje novčića odgovara slučajnom odabiru jednog primjera iz  $D$  i određivanju da li ga hipoteza  $h$  ispravno klasificira.

## Bacanje novčića

Zanima nas ishod:

*pala je glava*

## Slučajan pokus

## Hipoteza $h$ klasificira primjere

Zanima nas ishod:

*hipoteza  $h$  krivo klasificira primjer*

$\pi$

- vjerojatnost pada glave pri jednom bacanju novčića

$r$

- broj bacanja novčića u nizu od  $n$  čiji je ishod bio pad glave novčića

$r/n$

- proporcija pada glave u nizu od  $n$  bacanja novčića

$\text{error}_D(h)$

- vjerojatnost da će jedan slučajno izvučen primjer biti krivo klasificiran

$R$

- broj krivo klasificiranih primjera u uzorku od  $n$  slučajno odabranih primjera.

$\text{error}_S(h)$

- proporcija krivo klasificiranih primjera u slučajnom uzorku  $S$  od  $n$  elemenata

- Slučajna varijabla  $\text{error}_S(h)$  je varijabla binomne distribucije.
- Ako broj krivo klasificiranih primjera u uzorku  $S$  od  $n$  elemenata označimo s  $r$  možemo pisati da je

$$\text{error}_S(h) = r/n,$$

$$\text{error}_D(h) = \pi,$$

gdje je  $\pi$  vjerojatnost pogrešne klasifikacije jednog primjera.

- Vjerojatnost  $\pi$  nam nije poznata. Pomoću  $\text{error}_S(h)$  procjenjujemo  $\text{error}_D(h) = \pi$ .
- $\text{error}_S(h)$  je **procjenitelj** (*engl. estimator*) za pravu pogrešku.
- Procjenitelj je bilo koja slučajna varijabla pomoću koje procjenjujemo parametar populacije iz koje je izvučen slučajan uzorak.

- **Pristranost procjenitelja**  $Y$  za neki proizvoljan parametar  $p$  je

$$E[Y] - p.$$

- Ako je razlika  $E[Y] - p = 0$  kažemo da je **procjenitelj nepristran**.

- Napomena:  $E[Y]$  je očekivanje slučajne varijable  $Y$

*Primjer:*

- Srednja vrijednost uzorka je nepristran procjenitelj prave srednje vrijednosti populacije  $\mu$ .
  - **error<sub>s</sub>(h)** je nepristran procjenitelj za **error<sub>D</sub>(h)**.
  - Proporcija uzorka  $r/n$  je nepristran procjenitelj prave proporcije  $\pi$ .



- ***Važna napomena:*** Pristranost procjenitelja ne smije se zamijeniti s induktivnom pristranošću. Pristranost procjenitelja je numerička vrijednost dok je induktivna pristranost skup pretpostavki.
- Drugo važno svojstvo procjenitelja je njegova **varijanca**. Ako imamo izbor od više procjenitelja, razumno je izabrati onog s najmanjom varijansom.
- **Varijanca procjenitelja  $Y$** , tj. slučajne varijable  $Y$  je
$$V(Y) = E[(Y - EY)^2].$$
- Takav izbor će voditi najmanjoj očekivanoj kvadratnoj pogrešci između procjene i prave vrijednosti parametra.

# Standardna devijacija procjenitelja

- **Standardna devijacija procjenitelja naziva se standardna pogreška (SE)** (standardna devijacija je korijen od varijance).
- *Primjer:*
  - Varijanca slučajne varijable je  $\sigma^2/n$ . Standardna devijacija (tj. standardna pogreška) je  $\frac{\sigma}{\sqrt{n}}$ . (Centralni granični teorem!)
- *Primjer:*
  - Proporcija je binomna slučajna varijabla pomnožena s konstantom  $1/n$ .
  - Varijanca proporcije  $P$ ,  $V(P) = V(B/n) = 1/n^2 V(B) = \pi(1-\pi)/n$ .
  - Standardna pogreška proporcije  $P$  je  $SE(P) = \sigma_P = \sqrt{\frac{\pi(1-\pi)}{n}}$ .

# Standardna devijacija procjenitelja

- *Primjer:*
  - Uzorak od  $n=40$  slučajno odabranih primjera. Hipoteza  $h$  krivo klasificira  $r=12$  primjera.
  - $\text{error}_S(h) = r/n = 12/40 = 0.3$ , pa je nepristrana procjena za  $\text{error}_D(h)$  jednaka 0.3.
  - Standardna pogreška od  $\text{error}_S(h)$  jednaka je  $\sqrt{\frac{\pi(1-\pi)}{n}}$ .
- S obzirom da pravi  $\pi$  nemamo, zamjenjujemo ga s njegovim procjeniteljem  $r/n$  pa je

$$\sigma_{\text{error}_S(h)} = \frac{\sigma_{\text{binomne}}}{n} = \sqrt{\frac{0.3(1-0.3)}{40}} = 0.07$$

# Intervalne procjene proporcije

- Uzorak  $S$  sadrži  $n$  primjera izvučenih slučajno i nezavisno iz populacije s distribucijom  $D$ .

$$n > 30$$

hipoteza  $h$  krivo klasificira  $r$  od  $n$  primjera, tj.

$$\text{error}_S(h) = r/n.$$

- $S$  95% pouzdanošću stvarna pogreška leži u intervalu:

$$\text{error}_S(h) \pm 1.96 \sqrt{\frac{\text{error}_S(h)(1 - \text{error}_S(h))}{n}}$$

ili općenito

$$\text{error}_S(h) \pm u_p \sqrt{\frac{\text{error}_S(h)(1 - \text{error}_S(h))}{n}},$$

gdje izbor  $u_p$  određuje nivo pouzdanosti:

Nivo pouzdanosti	50%	68%	80%	90%	95%	98%	99%
$u_p$	0.67	1	1.28	1.64	1.96	2.33	2.58

# Intervalne procjene proporcije

- *Primjer:*

Uzorak S sadrži  $n = 40$  primjera.

Hipoteza  $h$  pogrešno klasificira  $r = 12$  primjera iz S.

- Proporcija pogreške hipoteze  $h$  na uzorku S dana je sa:

$$\text{error}_S(h) = r/n = 12/40 = 0.30.$$

- $\text{error}_S(h)$  je točkovna procjena za pravu proporciju pogreške hipoteze  $h$ , tj. za  $\text{error}_D(h)$ .
- Ako izvučemo drugi slučajni uzorak od 40 elemenata,  $\text{error}_S(h)$  će poprimiti neku drugu vrijednost zbog slučajnih odstupanja. Svaki uzorak daje drugu točkovnu procjenu.
- Kvalitetniju procjenu prave pogreške hipoteze  $h$  možemo dobiti ako odredimo interval pouzdanosti za pravu pogrešku.

# Intervalne procjene proporcije

- Odaberimo 95%-tni interval pouzdanosti. Iz tablica za jediničnu normalnu distribuciju U očitavamo da je pripadna vrijednost  $u_p$  za pouzdanost od 95% jednaka  $u_p = 1.96$ .
  - Standardna pogreška proporcije je  $\sqrt{\frac{(.3)(.7)}{40}} = 0.072$
  - Donja granica intervala pouzdanosti =  $.30 - (1.96)(.072) = .16$   
Gornja granica intervala pouzdanosti =  $.30 + (1.96)(.072) = .44$ .
- Prava se vrijednost pogreške hipoteze  $h$  nalazi u intervalu  $0.16 \leq \pi \leq 0.44$  i to možemo reći s 95% pouzdanosti.

# Intervalne procjene razlike proporcija dviju hipoteza

- Pretpostavimo da **uspoređujemo stope pogrešaka** dvije **hipoteze  $h_1$  i  $h_2$**  za neku ciljnu funkciju s diskretnim vrijednostima. Hipoteza  $h_1$  se provjerava na uzorku  $S_1$  koji sadrži  $n_1$  primjera slučajno izvučenih iz populacije, dok se  $h_2$  provjerava na uzorku  $S_2$  koji sadrži  $n_2$  primjera slučajno izvučenih iz populacije (osnovnog skupa s primjerima s nekom distribucijom  $D$ ).
- Pretpostavimo da želimo usporediti te dvije hipoteze tj. odrediti razliku u pogreškama koje čine te dvije hipoteze.  
$$\delta = \text{error}_D(h_1) - \text{error}_D(h_2)$$
- $\delta$  je parametar populacije koji želimo procijeniti.
- Procjenitelj je razlika proporcija pogreške hipoteza  $h_1$  i  $h_2$  određena na temelju uzoraka  $S_1$  i  $S_2$ .

$$d = \text{error}_{S_1}(h_1) - \text{error}_{S_2}(h_2).$$

# Intervalne procjene razlike proporcija dviju hipoteza

- Može se dokazati da je  $E[d] = \delta$ , što znači da je  $d$  nepristran procjenitelj za parametar  $\delta$ .
- Potrebno je poznavati distribuciju uzorkovanja  $d$  tj. pripadnu distribuciju vjerojatnosti za procjenitelj  $d$ .
- Znamo od prije da su za velike  $n_i$ , ( $n_i \geq 30$ ), slučajne varijable  $\text{error}_{s_1}(h_1)$  i  $\text{error}_{s_2}(h_2)$  distribuirane približno normalno (Moivre-Laplaceov teorem). Također vrijedi da je razlika dviju normalno distribuiranih slučajnih varijabli - opet normalno distribuirana slučajna varijabla s očekivanjem  $\delta$ . Može se pokazati da je standardna pogreška od  $d$  jednaka

$$SE(d) = \sigma_d = \sqrt{\frac{\text{error}_{s_1}(h_1)(1 - \text{error}_{s_1}(h_1))}{n_1} + \frac{\text{error}_{s_2}(h_2)(1 - \text{error}_{s_2}(h_2))}{n_2}}$$



# Intervalne procjene razlike proporcija dviju hipoteza

- Kada znamo da je procjenitelj  $d$  distribuiran normalno s parametrima: očekivanjem  $\delta$  i standardnom pogreškom  $\sigma_d$ , lako načinimo interval pouzdanosti za pravu razliku pogrešaka  $\delta$  koju čine hipoteze  $h_1$  i  $h_2$ .

$$\delta = d \pm u_p \sigma_d, \text{ s pouzdanošću ovisnom od } u_p$$

- U specijalnom slučaju možemo hipoteze  $h_1$  i  $h_2$  testirati na istom uzorku  $S$  i tada će  $d$  imati nešto manju varijancu.