

7. Regresija

prof. dr. sc. Bojana Dalbelo Bašić
doc. dr. sc. Jan Šnajder

Sveučilište u Zagrebu
Fakultet elektrotehnike i računarstva

Ak. god. 2012/13.

- 1 Uvod
- 2 Postupak najmanjih kvadrata
- 3 Poopćeni linearan model regresije
- 4 Odabir modela
- 5 Regularizirana regresija

- 1 Uvod
- 2 Postupak najmanjih kvadrata
- 3 Poopćeni linearan model regresije
- 4 Odabir modela
- 5 Regularizirana regresija

Regresija

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}, \quad \mathbf{x} \in \mathbb{R}^n, \quad y \in \mathbb{R} \quad \leftarrow$$

Hipoteza h aproksimira nepoznatu funkciju $f : \mathbb{R}^n \rightarrow \mathbb{R}$

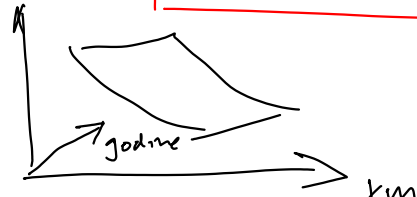
\mathbf{x} – ulazna varijabla (nezavisna, prediktorska)

y – izlazna varijabla (zavisna, kriterijska)

Funkcija pogreške:

$$E(h|\mathcal{D}) = \frac{1}{2} \sum_{i=1}^N (y^{(i)} - h(\mathbf{x}^{(i)}))^2$$

empirijska pogreška



Linearan model regresije:

h je linearna funkcija parametara $\mathbf{w} = (w_0, \dots, w_n)$

- Linearna regresija:

$$h(\mathbf{x}|\mathbf{w}) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$$



- Polinomijalna regresija:

$$h(\mathbf{x}|\mathbf{w}) = w_0 + w_1x + w_2x^2 + \dots + w_dx^d \quad (n = 1)$$

$$h(\mathbf{x}|\mathbf{w}) = w_0 + w_1x_1 + w_2x_2 + w_3x_1x_2 + w_4x_1^2 + w_5x_2^2 \quad (n = 2, d = 2)$$



- Općenite bazne funkcije:

$$h(\mathbf{x}|\mathbf{w}) = w_0 + w_1\phi_1(\mathbf{x}) + \dots + w_m\phi_m(\mathbf{x})$$


→ međuzavisnost
varijabli

Regresija

Broj ulaznih (nezavisnih) varijabli:

- Univarijatna (jednostavna, jednostruka) regresija: $n = 1$
- Multivarijatna (višestruka, multipla) regresija: $n > 1$

Broj izlaznih (zavisnih) varijabli:

- Jednoizlazna regresija: $f(\mathbf{x}) = y$  *ovo radimo*
- Višeizlazna regresija: $f(\mathbf{x}) = \mathbf{y}$

- 1 Uvod
- 2 Postupak najmanjih kvadrata
- 3 Poopćeni linearni model regresije
- 4 Odabir modela
- 5 Regularizirana regresija

Probabilistički model regresije

Ograničimo se BSO na univarijatnu ($n = 1$) linearnu regresiju:

$$h(x|\mathbf{w}) = w_0 + w_1x$$

$$\mathbf{w} = (w_0, w_1)$$

Zbog šuma u \mathcal{D} :

$$y^{(i)} = f(x^{(i)}) + \varepsilon$$

Prepostavka:

$$\varepsilon \sim \mathcal{N}(0, \sigma^2)$$


Posjedično:

$$y|x \sim \mathcal{N}(h(x|\mathbf{w}), \sigma^2)$$

odnosno

$$p(y|x) = \mathcal{N}(h(x|\mathbf{w}), \sigma^2)$$

$$\mathbb{E}[y|x] = \mu = h(x|\mathbf{w})$$




Probabilistički model regresije

$$\mathcal{D} = \{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), (x^{(3)}, y^{(3)})\}$$

$$P(\mathcal{D}/w) = P(x^{(1)}, y^{(1)}) \cdot P(x^{(2)}, y^{(2)}) \cdot P(x^{(3)}, y^{(3)})$$

$$= P_1 \cdot P_2 \cdot P_3 \quad (\text{v. idući slajd})$$



$P_i \rightarrow$ vjerojatost da je y^i zbog šuma toliko udaljena od $h(x^i/w)$

$$\ln \mathcal{L}(\mathbf{w}|\mathcal{D}) = \ln p(\mathcal{D}|\mathbf{w}) = \ln \prod_{i=1}^N p(x^{(i)}, y^{(i)}) = \ln \prod_{i=1}^N p(y^{(i)}|x^{(i)})p(x^{(i)})$$

$$= \ln \prod_{i=1}^N p(y^{(i)}|x^{(i)}) + \ln \prod_{i=1}^N p(x^{(i)})$$

ne ovisi o w

$$\Rightarrow \ln \prod_{i=1}^N p(y^{(i)}|x^{(i)}) = \ln \prod_{i=1}^N \mathcal{N}(h(x^{(i)}|\mathbf{w}), \sigma^2)$$

$$= \ln \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ - \frac{(y^{(i)} - h(x^{(i)}|\mathbf{w}))^2}{2\sigma^2} \right\}$$

↓ = μ

$$= -N \ln(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^N (y^{(i)} - h(x^{(i)}|\mathbf{w}))^2$$

konst.

$$\Rightarrow \frac{1}{2} \sum_{i=1}^N (y^{(i)} - h(x^{(i)}|\mathbf{w}))^2$$

zbog kvadratnih odstupanja

MLE i postupak najmanjih kvadrata

Uz pretpostavku Gaussovog šuma, **maksimizacija izglednosti** odgovara minimizaciji funkcije pogreške definirane kao **zbroj kvadratnih odstupanja**:

$$\operatorname{argmax}_{\mathbf{w}} \ln \mathcal{L}(\mathbf{w}|\mathcal{D}) = \operatorname{argmin}_{\mathbf{w}} E(\mathbf{w}|\mathcal{D})$$

$$E(h|\mathcal{D}) = \frac{1}{2} \sum_{i=1}^N (y^{(i)} - h(x^{(i)}|\mathbf{w}))^2$$

$$L(y, h(x|\mathbf{w})) \propto (y - h(x|\mathbf{w}))^2$$

⇒ Probabilističko opravdanje za kvadratnu funkciju gubitka

Rješenje MLE jednako je rješenju koje daje postupak najmanjih kvadrata!

Postupak najmanjih kvadrata

$$\boxed{h(x|w_0, w_1) = w_0 + w_1 x} \quad \text{model}$$

$$\nabla_{w_0, w_1} E(h|\mathcal{D}) = 0$$

\vdots

$$\sum_{i=1}^N y^{(i)} = Nw_0 + w_1 \sum_{i=1}^N x^{(i)}$$

(1.3) u skripti

$$\sum_{i=1}^N y^{(i)} x^{(i)} = w_0 \sum_{i=1}^N x^{(i)} + w_1 \sum_{i=1}^N (x^{(i)})^2$$

(1.5) u skripti

Matrični oblik: $\boxed{\mathbf{A}\mathbf{w} = \mathbf{z}}$ $\left[\begin{matrix} A \end{matrix} \right] \left[\begin{matrix} w \end{matrix} \right] = \left[\begin{matrix} z \end{matrix} \right]$

$$\mathbf{A} = \begin{pmatrix} N & \sum_i x^{(i)} \\ \sum_i x^{(i)} & \sum_i (x^{(i)})^2 \end{pmatrix}$$

$$\mathbf{w} = \begin{pmatrix} w_0 \\ w_1 \end{pmatrix}$$

$$\mathbf{z} = \begin{pmatrix} \sum_i y^{(i)} \\ \sum_i y^{(i)} x^{(i)} \end{pmatrix}$$

Rješenje: $\boxed{\mathbf{w} = \mathbf{A}^{-1}\mathbf{z}}$

$\hookleftarrow \mathbf{A}^{-1}\mathbf{A}\mathbf{w} = \mathbf{A}^{-1}\mathbf{z}$

- 1 Uvod
- 2 Postupak najmanjih kvadrata
- 3 Poopćeni linearni model regresije**
- 4 Odabir modela
- 5 Regularizirana regresija

Bazne funkcije

Zanima nas poopćenje na $n > 1$ koje obuhvaća sve multivarijatne linearne modele regresije (univarijatna regresija, linearna regresija, polinomijalna regresija, ...).

Uvodimo fiksni skup **baznih funkcija** (nelinearne funkcije ulaznih varijabli):

$$\{\phi_j(\mathbf{x})\}_{j=1}^m \quad \phi_j : \mathbb{R}^n \rightarrow \mathbb{R}$$

(Dogovorno: $\phi_0(\mathbf{x}) = 1$)

Funkcija preslikavanja (vektor baznih funkcija):

$$\phi(\mathbf{x}) = (\phi_0(\mathbf{x}), \dots, \phi_m(\mathbf{x}))$$

$$\phi : \mathbb{R}^n \rightarrow \mathbb{R}^m$$

ulazni prostor

prostor značajki
(feature space)

Općenit linearan model:

$$h(\mathbf{x}|\mathbf{w}) = \sum_{j=0}^m w_j \phi_j(\mathbf{x}) = \underline{\underline{\mathbf{w}^T \phi(\mathbf{x})}}$$

Poopćeni linearan model

$$h(\mathbf{x}|\mathbf{w}) = \sum_{j=0}^m w_j \phi_j(\mathbf{x}) = \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x})$$

- Linearna regresija:

$$\boldsymbol{\phi}(\mathbf{x}) = (1, x_1, x_2, \dots, x_n) \quad n+1$$

- Univarijatna polinomijalna regresija:

$$\boldsymbol{\phi}(x) = (1, x, x^2, \dots, x^m)$$

- Polinomijalna regresija drugog stupnja:


$$\boldsymbol{\phi}(\mathbf{x}) = (1, x_1, x_2, x_1 x_2, x_1^2, x_2^2) \quad \begin{matrix} n=2 \\ m=6 \end{matrix}$$

- Gaussove bazne funkcije:

$$\phi_j(x) = \exp \left\{ - \frac{(x - \mu_j)^2}{2\sigma^2} \right\}$$

Gaussove bazne funkcije

(Općenito: radijalne bazne funkcije, RBF)



$$h(x|w) = w_1 \cdot \phi_1(x) + w_2 \cdot \phi_2(x) + w_3 \cdot \phi_3(x) + w_4 \cdot \phi_4(x) + w_5 \cdot \phi_5 = \underline{\Phi}(x)^T w$$


↪ nelinearna fja u
ulažnom prostoru

ali $\underline{\Phi}(x)^T w$ je linearna u prostoru
značajki!

Preslikavanje značajki

Funkcija preslikavanja značajki $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^m$ preslikava primjere iz n -dimenzijskog **ulaznog prostora** (engl. *input space*) u m -dimenzijski **prostor značajki** (engl. *feature space*).

Tipično je $m > n$. Funkcija koja je linearna u prostoru značajki je nelinearna u ulaznom prostoru.



- sada možemo koristiti linearan model za nelinearne probleme
- imamo jedinstven matematički tretman, neovisan o funkciji ϕ

Matrično rješenje najmanjih kvadrata

Dizajn-matrica:

1. primjer \rightarrow

$$\Phi = \begin{pmatrix} 1 & \phi_1(\mathbf{x}^{(1)}) & \dots & \phi_m(\mathbf{x}^{(1)}) \\ 1 & \phi_1(\mathbf{x}^{(2)}) & \dots & \phi_m(\mathbf{x}^{(2)}) \\ \vdots & \vdots & \ddots & \vdots \\ 1 & \phi_1(\mathbf{x}^{(N)}) & \dots & \phi_m(\mathbf{x}^{(N)}) \end{pmatrix} = \begin{pmatrix} \phi(\mathbf{x}^{(1)})^T \\ \phi(\mathbf{x}^{(2)})^T \\ \vdots \\ \phi(\mathbf{x}^{(N)})^T \end{pmatrix}_{N \times m}$$

N -ti primjer \rightarrow

Vektor izlaznih vrijednosti:

$$\mathbf{y} = \begin{pmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(N)} \end{pmatrix}$$

$N \times m$ $m \times 1$ $N \times 1$
 $\begin{bmatrix} \Phi \end{bmatrix} \begin{bmatrix} \mathbf{w} \end{bmatrix} = \begin{bmatrix} \mathbf{y} \end{bmatrix}$

Matrična jednadžba (N jednadžbi s m nepoznanica):

$$\Phi \mathbf{w} = \mathbf{y}$$

Matrično rješenje najmanjih kvadrata

Rješenje je $\mathbf{w} = \Phi^{-1}\mathbf{y}$

Međutim, rješenja nema ili ono nije jedinstveno ako:

(1) Φ nije kvadratna, pa nema inverz. U pravilu:

- $N > m$
 \Rightarrow sustav je **preodređen** (engl. *overdetermined*) i nema rješenja
- $N < m$
 \Rightarrow sustav je **pododređen** (engl. *underdetermined*) i ima višestruka rješenja

(2) Φ jest kvadratna ($N = m$), ali ipak nema inverz

\Rightarrow sustav je **nekonzistentan**

Približno rješenje možemo naći **postupkom najmanjih kvadrata**

\Rightarrow minimizacija kvadrata pogreške svake od jednačbi

\rightarrow u smislu najmanjih kvadrata

Matrično rješenje najmanjih kvadrata

Funkcija pogreške:

$$E(\mathbf{w}|\mathcal{D}) = \frac{1}{2} \sum_{i=1}^N (\mathbf{w}^T \phi(\mathbf{x}^{(i)}) - y^{(i)})^2$$

Matrični oblik:

$$\begin{aligned} E(\mathbf{w}|\mathcal{D}) &= \frac{1}{2} (\Phi \mathbf{w} - \mathbf{y})^T (\Phi \mathbf{w} - \mathbf{y}) \\ &= \frac{1}{2} (\mathbf{w}^T \Phi^T \Phi \mathbf{w} - \mathbf{w}^T \Phi^T \mathbf{y} - \mathbf{y}^T \Phi \mathbf{w} + \mathbf{y}^T \mathbf{y}) \\ &= \frac{1}{2} (\mathbf{w}^T \Phi^T \Phi \mathbf{w} - 2\mathbf{y}^T \Phi \mathbf{w} + \mathbf{y}^T \mathbf{y}) \end{aligned}$$

$$= (\mathbf{w}^T \Phi^T \mathbf{y})^T = \mathbf{y}^T \Phi \mathbf{w}$$

$$(\mathbf{A} \mathbf{B})^T = \mathbf{B}^T \mathbf{A}^T$$

Matrično rješenje najmanjih kvadrata

$$E(\mathbf{w}|\mathcal{D}) = \frac{1}{2}(\mathbf{w}^T \Phi^T \Phi \mathbf{w} - 2\mathbf{y}^T \Phi \mathbf{w} + \mathbf{y}^T \mathbf{y})$$

$$\nabla_{\mathbf{w}} E = \frac{1}{2} \left(\mathbf{w}^T (\Phi^T \Phi + (\Phi^T \Phi)^T) - 2\mathbf{y}^T \Phi \right) = \Phi^T \Phi \mathbf{w} - \Phi^T \mathbf{y} = 0$$

$$\frac{d}{dx} x^T A x = x^T (A + A^T) \quad \frac{d}{dx} A x = A$$

Sustav **normalnih** jednadžbi:

$$\Phi^T \Phi \mathbf{w} = \Phi^T \mathbf{y} \quad / \cdot (\Phi^T \Phi)^{-1}$$

Rješenje:

$$\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{y} = \Phi^+ \mathbf{y}$$



$\Phi^+ = (\Phi^T \Phi)^{-1} \Phi^T$ je **pseudoinverz** (Moore-Penroseov inverz) matrice Φ

- 1 Uvod
- 2 Postupak najmanjih kvadrata
- 3 Poopćeni linearan model regresije
- 4 Odabir modela**
- 5 Regularizirana regresija

Odabir modela

Linearan model regresije ima **hiperparametre**:

- izgled baznih funkcija ϕ_j
- broj baznih funkcija m (dimenzija prostora značajki)


Parametre treba namjestiti tako da odgovaraju podacima, odnosno treba dobro **odabrati model**. U suprotnom model može biti podnaučen ili prenaučen. Ako model ima mnogo parametra, lako ga je prenaučiti.

Sprečavanje prenaučenosti:

- (1) koristiti više primjera za učenje
- (2) odabrati model unakrsnom provjerom
- (3) regularizacija
- (4) bayesovska regresija

↪ su 2

← danas



- 1 Uvod
- 2 Postupak najmanjih kvadrata
- 3 Poopćeni linearan model regresije
- 4 Odabir modela
- 5 Regularizirana regresija**

Regularizacija – motivacija

Opažanje: kod linearnih modela, što je model složeniji, to ima veće vrijednosti parametara w .

$$h(x|w) = w_0 + w_1 x + w_2 x^2 + w_3 x^3$$

0 = 0 =

Prenaučeni linearni modeli imaju:

- (1) ukupno previše parametara (težina) i/ili
- (2) prevelike vrijednosti pojedinačnih parametara.



Ideja: **ograničiti rast vrijednosti parametara** kažnjavanjem hipoteza s visokim vrijednostima parametara.

Time se ostvaruje **kompromis** između točnosti i jednostavnosti modela i to već pri samom učenju modela. Efektivno se ograničava složenost modela i sprečava se prenaučенost.

Cilj: što više parametara (težina) pritegnuti na nulu \Rightarrow **rijetki modeli** (engl. *sparse models*).
interpretibilni + računalo 'jednostavniji' \leftarrow

Regularizacija

Složenost modela ugrađena je u funkciju pogreške:

$$E' = \text{empirijska pogreška} + \lambda \times \text{složenost modela}$$

regularizacijski faktor \rightarrow *regularizacijski izraz*

$$E'(\mathbf{w}|\mathcal{D}) = E(\mathbf{w}|\mathcal{D}) + \lambda E_w(\mathbf{w})$$

Veća vrijednost regularizacijskog faktora λ uzrokuje smanjenje efektivne složenost modela.

$\lambda = 0 \Rightarrow$ neregularizirana funkcija pogreške

Općenit regularizacijski izraz:

ne regularizirani w_0 !


$$E_w(\mathbf{w}) = \frac{1}{2} \sum_{j=1}^m |w_j|^q$$

\rightarrow *2-norma*

Regularizacija – primjer

Npr. $n=1$, $m=6$:

$$h(x|w) = w_0 + w_1x + w_2x^2 + w_3x^3 + \dots + w_6x^6$$



Regularizirani linearni model regresije

L2-regularizacija (engl. *ridge regularization*) ($q = 2$)

$$E(\mathbf{w}|\mathcal{D}) = \frac{1}{2} \sum_{i=1}^N (\mathbf{w}^T \phi(\mathbf{x}^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

(ima rješenje u zatvorenoj formi)

L1-regularizacija (engl. *LASSO regularization*) ($q = 1$) (nema rješenja u zatvorenoj formi)

$$E(\mathbf{w}|\mathcal{D}) = \frac{1}{2} \sum_{i=1}^N (\mathbf{w}^T \phi(\mathbf{x}^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2} \|\mathbf{w}\|_1$$

L0-regularizacija ($q = 0$)

(NP-complete)

$$E(\mathbf{w}|\mathcal{D}) = \frac{1}{2} \sum_{i=1}^N (\mathbf{w}^T \phi(\mathbf{x}^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2} \sum_{j=1}^m \mathbf{1}\{w_j \neq 0\}$$

L2-regularizacija

Linearna regresija s L2-regularizacijom ima rješenje u zatvorenoj formi:

$$\begin{aligned} E'(\mathbf{w}|\mathcal{D}) &= \frac{1}{2}(\Phi\mathbf{w} - \mathbf{y})^T(\Phi\mathbf{w} - \mathbf{y}) + \frac{\lambda}{2}\mathbf{w}^T\mathbf{w} \quad \longrightarrow \quad \mathbf{w}^T\mathbf{w} = \|\mathbf{w}\|^2 \\ &= \frac{1}{2}(\mathbf{w}^T\Phi^T\Phi\mathbf{w} - 2\mathbf{y}^T\Phi\mathbf{w} + \mathbf{y}^T\mathbf{y} + \lambda\mathbf{w}^T\mathbf{w}) \end{aligned}$$

$$\begin{aligned} \nabla_{\mathbf{w}}E' &= \Phi^T\Phi\mathbf{w} - \Phi^T\mathbf{y} + \lambda\mathbf{w} \\ &= (\Phi^T\Phi + \lambda\mathbf{I})\mathbf{w} - \Phi^T\mathbf{y} = 0 \end{aligned}$$

$$\boxed{\mathbf{w} = (\Phi^T\Phi + \lambda\mathbf{I})^{-1}\Phi^T\mathbf{y}}$$

$$\longrightarrow \mathbf{I} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

L2-regularizacija

Ima li L2-regularizirana pogreška probabilističku interpretaciju?

Umjesto MLE, izračunajmo MAP:

$$p(\mathbf{w}|\mathcal{D}) \propto p(\mathcal{D}|\mathbf{w})p(\mathbf{w})$$

apriorna razdioba
težina

Izglednost je normalna sa srednjom vrijednošću $h(\mathbf{x}|\mathbf{w})$:

$$p(\mathcal{D}|\mathbf{w}) = \prod_{i=1}^N \mathcal{N}(h(\mathbf{x}^{(i)}|\mathbf{w}), \beta^{-1}) \quad (\beta = 1/\sigma^2)$$

μ σ^2 \rightarrow "preciznost"

Pretpostavimo da apriorna PDF parametara normalna sa srednjom vrijednošću nula i izotropnom kov. matricom:



$$p(\mathbf{w}) = \mathcal{N}(0, \alpha^{-1}\mathbf{I}) \stackrel{\checkmark D^2}{=} \left(\frac{\alpha}{2\pi}\right)^{m/2} \exp\left\{-\frac{\alpha}{2}\mathbf{w}^T\mathbf{w}\right\} \quad (\alpha = 1/\sigma^2)$$



(α i β su hiperparametri modela)

MAP procjena

$$P(w|D) \propto P(D|w) \cdot P(w) \quad \text{MAP}$$



x

Gauss

$$\mu = h(x|w)$$

$$\sigma^2 = \beta^{-1}$$

konjugatni par

Gauss

$$\mu = 0$$

$$\sigma^2 = \alpha^{-1}$$

L2-regularizacija

Maksimizacija aposteriorne vjerojatnosti **istovjetna je minimizaciji logaritma aposteriorne vjerojatnosti:**

$$\operatorname{argmax}_{\mathbf{w}} p(\mathcal{D}|\mathbf{w})p(\mathbf{w}) = \operatorname{argmin}_{\mathbf{w}} (\ln p(\mathcal{D}|\mathbf{w}) + \ln p(\mathbf{w}))$$

$$\ln p(\mathcal{D}|\mathbf{w}) = \frac{\beta}{2} \sum_{i=1}^N (y^{(i)} - h(\mathbf{x}|\mathbf{w}))^2 + \text{konst.} \quad \ln p(\mathbf{w}) = \frac{\alpha}{2} \mathbf{w}^T \mathbf{w}$$

Dakle, pogreška koju minimiziramo je:

$$\left[\frac{\beta}{2} \sum_{i=1}^N (y^{(i)} - h(\mathbf{x}|\mathbf{w}))^2 + \frac{\alpha}{2} \mathbf{w}^T \mathbf{w} \right] \quad / : \beta$$

a to je upravo L2-regularizirana pogreška! (uz $\lambda = \alpha/\beta$)


Regularizacija – napomene

- Iznos parametra w_j odgovara važnosti značajke, a predznak upućuje na njezin utjecaj (pozitivan ili negativan) na izlaznu vrijednost
- Regularizacija smanjuje složenost modela na način da prigušuje vrijednosti pojedinih značajki, odnosno efektivno ih izbacuje (kada $w_j \rightarrow 0$). Ako je model nelinearan, to znači smanjivanje nelinearnosti
- Težinu w_0 treba izuzeti iz regularizacijskog izraza (jer ona definira pomak) ili treba centrirati podatke tako da $\bar{y} = 0$, jer onda $w_0 \rightarrow 0$
- L2-regularizacija kažnjava težine proporcionalno njihovom iznosu (velike težine više, a manje težine manje). Teško će parametri biti pritegnuti baš na nulu. Zato **L2-regularizacija ne rezultira rijetkim modelima**
- L1-regularizacija rezultira rijetkim modelima, ali nema rješenja u zatvorenoj formi (međutim mogu se koristiti iterativni optimizacijski postupci)

Regularizacija – napomene

- Regularizacija je korisna kod modela s puno parametara, jer je takve modele lako prenaučiti
- Regularizacija smanjuje mogućnost prenaučivosti, ali ostaje problem odabira hiperparametra λ te drugih hiperparametara (broj i oblik baznih funkcija). Taj se odabir najčešće radi **unakrsnom provjerom**

Q: Koju optimalnu vrijednost za λ bismo dobili kada bismo optimizaciju radili na skupu za učenje?



- **Linearan model regresije** linearan je u parametrima
- Nelinearnost regresijske funkcije ostvaruje se uporabom nelinearnih **baznih funkcija** (preslikavanjem ulaznog prostora u prostor značajki)
- Uz pretpostavku normalno distribuiranog šuma, **MLE je istovjetan postupku najmanjih kvadrata**, što daje probabilističko opravdanje za uporabu kvadratne funkcije gubitka
- Parametri linearnog modela uz kvadratnu funkciju gubitka imaju rješenje u zatvorenoj formi u obliku **pseudoinverza dizajn-matrice**
- **Regularizacija smanjuje prenaučенost** ugradnjom dodatnog izraza u funkciju pogreške kojim se kažnjava složenost modela
- **L2-regularizirana regresija istovjetna je MAP-procjeni** parametara (uz pretpostavku Gaussovog šuma) te ima rješenje u zatvorenoj formi



Sljedeća tema: Linearni diskriminativni modeli