


Prof.dr.sc. Bojana Dalbello Bašić

Fakultet elektrotehnike i računarstva  
Zavod za elektroniku, mikroelektroniku, računalne i inteligentne sustave

[www.zemris.fer.hr/~bojana](http://www.zemris.fer.hr/~bojana)  
[bojana.dalbello@fer.hr](mailto:bojana.dalbello@fer.hr)

# Stabla odluke

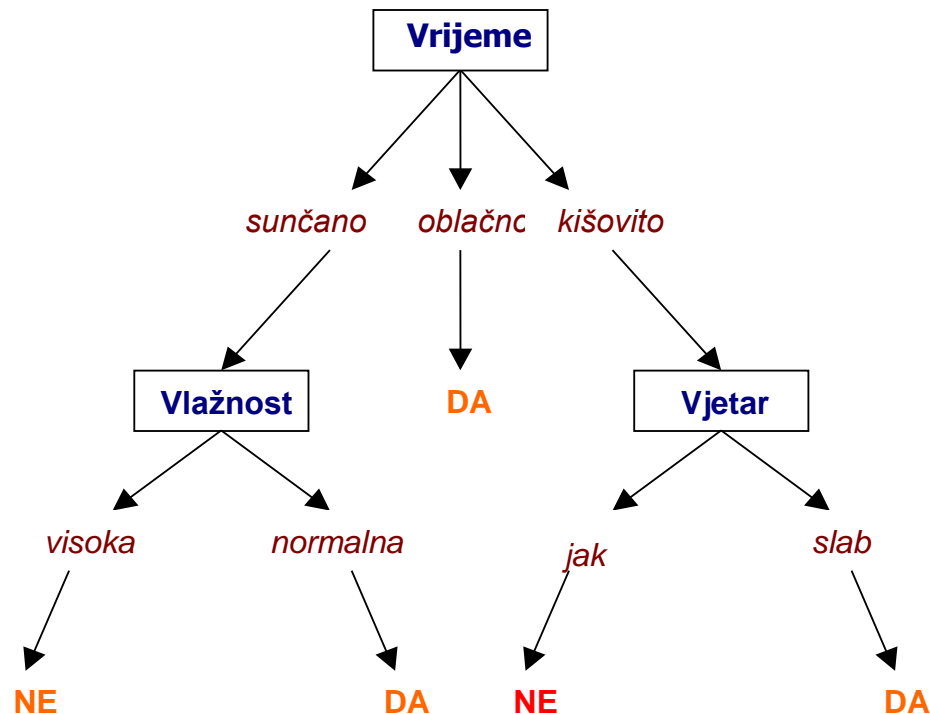


- Najčešće korištena metoda induktivnog zaključivanja (medicina, financije..)
- **Neparametarska metoda**
- **Diskriminativna metoda**
- Metoda aproksimiranja funkcije diskretnih (i kontinuiranih vrijednosti -> CART) robusna na šum, koja može učiti disjunktivne koncepte.
- Familija algoritama: **ID3**, ASSISTANT, C4.5,
- Pretražuju potpun prostor hipoteza (pristranost?)
- Stabla odluke → (reinterpretacija) → skup ako-onda pravila

# PREDSTAVLJANJE STABLA ODLUKE

- Klasifikacija primjera odozgo, od korijena prema listovima
  - Čvor (*engl. node*) – test atributa
  - Grana (*engl. branch*) – odgovara vrijednosti atributa

Primjer: **Klasifikacija DA/NE** - Je li subotnje jutro pogodno za tenis?



# PREDSTAVLJANJE STABLA ODLUKE

*Primjer:*

- (**Vrijeme** = *sunčano*, **Temperatura** = *vruće*, **Vlažnost** = *visoka*, **Vjetar** = *jak*) → (**Igranje\_tenisa** = **NE**)
- Općenito, stabla odluke predstavljaju disjunkciju konjunkcije uvjeta na vrijednosti atributa:  
$$(\mathbf{Vrijeme} = \textit{sunčano} \wedge \mathbf{Vlažnost} = \textit{normalna}) \vee (\mathbf{Vrijeme} = \textit{oblačno}) \vee (\mathbf{Vrijeme} = \textit{kišovito} \wedge \mathbf{Vjetar} = \textit{jak})$$

*(DNF – disjunktivna normalna forma)*

## Prikladni za probleme kod kojih...

- Primjeri su predstavljeni parovima atribut – vrijednost (posebno: mali broj mogućih vrijednosti atributa)
- Ciljna funkcija poprima diskretne vrijednosti (u gornjem primjeru Booleova klasifikacija: DA i NE). Algoritam se može proširiti i na učenje funkcije s više vrijednosti ili s realnim vrijednostima
- Stabla odluke prirodno predstavljaju disjunktivni izraz
- Podaci za učenje mogu sadržavati pogreške
- Tolerantnost na nedostajuće vrijednosti

# OSNOVNI ALGORITAM UČENJA STABLA ODLUKE

- Quinlan, J.R. (1986) Induction of Decision Trees. *Machine Learning*, 1(1), 81-106
- Temeljni algoritam **Quinlan** je nazvao ID3, a proširenje C4.5 (Quinlan, 1993).
- **ID3** (engl. *Induction of **D**ecision **T**rees*)

# OSNOVNI ALGORITAM UČENJA STABLA ODLUKE

Koji atribut odabrati za testiranje?

- testira se svaki atribut da se ocijeni kako dobro klasificira primjere
- najbolji se odabire kao čvor, a njegove vrijednosti su silazne grane
- primjeri za učenje sortiraju se prema odgovarajućem silaznom čvoru (niz onu granu koja odgovara vrijednosti tog atributa)
- cijeli postupak se ponavlja koristeći primjere koji su dodijeljeni silaznome čvoru
- ID3 spada u **pohlepne algoritme** (*engl. greedy*) zato jer se nikad ne vraća zbog ponovnog razmatranja prethodnih čvorova

# KOJI ATRIBUT JE NAJBOLJI KLASIFIKATOR?

Najvažniji izbor:

- **Odabir atributa koji će se testirati u pojedinom čvoru stabla**
- Koja je dobra kvantitativna mjera vrijednosti nekog atributa?
- **Informacijska dobit** (*engl. information gain*) – mjera kako dobro pojedini atribut odjeljuje primjere za učenje u skladu s ciljnom klasifikacijom



# ENTROPIJA MJERI HOMOGENOST PRIMJERA

- Neka skup D sadrži pozitivne i negativne primjere nekog ciljnog koncepta. **Entropija** u odnosu na skup D jest:

$$\text{Entropija}(D) \equiv - p_+ \log_2 p_+ - p_- \log_2 p_-$$

gdje je:

- **p<sub>+</sub>** proporcija pozitivnih primjera u D,
- **p<sub>-</sub>** proporcija negativnih primjera u D.
- Po definiciji:  $0 \log_2 0 \equiv 0$

# ENTROPIJA MJERI HOMOGENOST PRIMJERA


*Primjer:*

- D se sastoji od 14 primjera: 9 pozitivnih i 5 negativnih primjera.
- Usvojena notacija **[9+, 5-]**
- **Entropija**([9+, 5-]) =  $-(9/14) \log_2 (9/14) - (5/14) \log_2 (5/14)$   
**= 0.940**

1. Ako svi primjeri pripadaju istoj klasi, kolika je entropija?
2. Kolika je entropija za skup D koji sadrži isti broj pozitivnih i negativnih primjera?

# ENTROPIJA MJERI HOMOGENOST PRIMJERA

- Interpretacija entropije: *minimalan broj bitova potreban za kodiranje klasifikacije proizvoljnih članova skupa  $D$*



- U slučaju  $K$  klasa:

$$\text{Entropija}(D) = \sum_{j=1}^K -P(C_j) \log_2 P(C_j)$$

Entropija mjeri stupanj «neurednosti» podataka

# INFORMACIJSKA DOBIT MJERI OČEKIVANU REDUKCIJU U ENTROPIJI

**Informacijska dobit** je očekivana redukcija entropije uzrokovana podjelom primjera za učenje u skladu s tim atributom

- **Informacijska dobit** (*engl. gain*) atributa A u odnosu na skup primjera D jest:

$$\text{Informacijska\_dobit}(D, A) \equiv \text{Entropija}(D) - \sum_{v \in \text{Vrijednosti}(A)} \frac{|D_v|}{|D|} \text{Entropija}(D_v)$$

Entropija izvornog skupa D

Očekivana vrijednost entropije nakon podjele D na temelju atributa A

- Vrijednosti(A) - skup svih mogućih vrijednosti atributa A
- $D_v$  - podskup od D za koji atribut A ima vrijednost v, tj.  
 $D_v = \{x \in D \mid A(x) = v\}$

# INFORMACIJSKA DOBIT MJERI OČEKIVANU REDUKCIJU U ENTROPIJI

- Informacijska dobit  $IG(D, A)$  je informacija o vrijednosti ciljne funkcije, ako je dana vrijednost atributa  $A$
- Vrijednost  $IG(D, A)$  je ušteđen broj bitova sačuvan kod kodiranja ciljne funkcije proizvoljnog člana iz skupa primjera  $D$ , ako je poznata vrijednost atributa  $A$

*Primjer:*

- Neka je  $D$  skup primjera opisan atributom **Vjetar** = {*jak*, *slab*} i neka  $D$  ima 14 primjera , 9+ i 5-.
- Od tih 14 primjera,
  - ukupno 8 primjera (6 pozitivnih i 2 negativna) imaju vrijednost **Vjetar** = *slab*
  - ostatak 6 primjera, (3 pozitivna i 3 negativna ) ima vrijednost **Vjetar** = *jak*

# INFORMACIJSKA DOBIT MJERI OČEKIVANU REDUKCIJU U ENTROPIJI

- Informacijska dobit od klasificiranja izvornih 14 primjera po atributu *vjetar* se računa na slijedeći način:

$A = \mathbf{Vjetar}$

Vrijednost ( $\mathbf{Vjetar}$ ) = *slab, jak*

$D = [9+, 5-]$

$D_{\text{slab}} \leftarrow [6+, 2-] \dots$  ukupno 8 primjera

$D_{\text{jak}} \leftarrow [3+, 3-] \dots$  ukupno 6 primjera

**Informacijska dobit (*Gain*)** zbog odjeljivanja primjera skupa  $D$  na temelju vrijednosti atributa  $\mathbf{Vjetar}$  jest:

$$\text{Informacijska\_dobit}(D, A) \equiv \text{Entropija}(D) - \sum_{v \in \text{Vrijednosti}(A)} \frac{|D_v|}{|D|} \text{Entropija}(D_v)$$

## INFORMACIJSKA DOBIT MJERI OČEKIVANU REDUKCIJU U ENTROPIJI


- Najprije računamo entropije skupova  $D$ ,  $D_{\text{slab}}$ ,  $D_{\text{jak}}$   
 $Entropija(D) = 0.940$  (vidi prethodni primjer!)  
 $Entropija(D_{\text{slab}}) = Entropija([6+, 2-]) = - (6/8)\log_2(6/8) - (2/8)\log_2(2/8) = 0.811$   
 $Entropija(D_{\text{jak}}) = Entropija([3+, 3-]) = - (3/6)\log_2(3/6) - (3/6)\log_2(3/6) = 1$
- $Informacijska\_dobit(D, Vjetar) \equiv$   
 $\equiv Entropija(D) - (8/14)Entropija(D_{\text{slab}}) -$   
 $(6/14)Entropija(D_{\text{jak}})$   
 $\equiv 0.940 - (8/14)0.811 - (6/14)1.00 \equiv \mathbf{0.048}$

- Da bismo ilustrirali algoritam ID3 promotrimo sljedeći primjer
- **Vrijeme** {sunčano, oblačno, kišno}
- **Temperatura** {hladno, ugodno, vruće}
- **Vlažnost**{velika, normalna}
- **Vjetar** {jak, slab}
- Računamo informacijsku dobit sva četiri atributa da bismo odredili atribut s najvećom informacijskom dobiti koji će postati korijen stabla

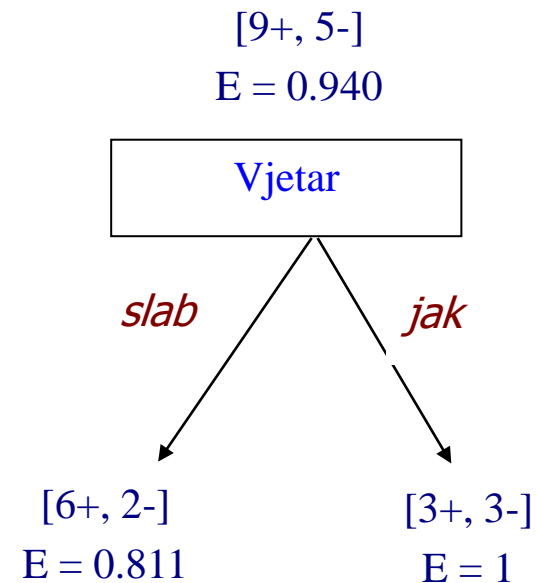


# PRIMJER

	Vrijeme	Temperatura	Vlažnost	Vjetar	Igra
1.	sunčano	vruće	velika	slab	NE
2.	sunčano	vruće	velika	jak	NE
3.	oblačno	vruće	velika	slab	DA
4.	kišno	ugodno	velika	slab	DA
5.	kišno	hladno	normalna	slab	DA
6.	kišno	hladno	normalna	jak	NE
7.	oblačno	hladno	normalna	jak	DA
8.	sunčano	ugodno	velika	slab	NE
9.	sunčano	hladno	normalna	slab	DA
10.	kišno	ugodno	normalna	slab	DA
11.	sunčano	ugodno	normalna	jak	DA
12.	oblačno	ugodno	velika	jak	DA
13.	oblačno	vruće	normalna	slab	DA
14.	kišno	ugodno	Velika	jak	NE
	sunčano[2+,3-] oblačno[4+,0-] kišno[3+,2-]	hladno[3+,1-] ugodno[4+,2-] vruće[2+,2-]	velika [3+, 4-] normalna [6+, 1-]	slab [6+, 2-] jak [3+, 3-]	[9+, 5-]




$$\begin{aligned} \text{Informacijska\_dobit}(D, \text{Vlažnost}) &= 0.940 - (7/14) 0.985 - (7/14) 0.592 \\ &= \mathbf{0.151 \text{ bita}} \end{aligned}$$

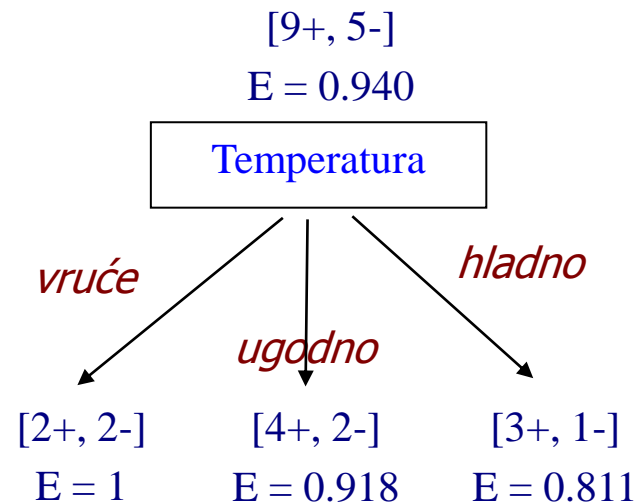


$$\begin{aligned} \text{Informacijska\_dobit}(D, \text{Vjetar}) &= 0.940 - (8/14) 0.811 - (6/14) 1 \\ &= \mathbf{0.048 \text{ bita}} \end{aligned}$$

# PRIMJER



$$\begin{aligned}\text{Informacijska\_dobit}(D, \text{Vrijeme}) &= 0.940 - (5/14) 0.971 - (4/14) 0 \\ &= (5/14) 0.971 = \mathbf{0.246 \text{ bita}}\end{aligned}$$



$$\begin{aligned}\text{Informacijska\_dobit}(D, \text{Temperatura}) &= 0.940 - (4/14) 1 - (6/14) 0.918 - (4/14) 0.811 \\ &= \mathbf{0.029 \text{ bita}}\end{aligned}$$


**Najveća informacijska dobit od sva četiri moguća atributa, pa će atribut **Vrijeme** biti korijen stabla!**

- **ID3** - Korijen stabla je **Vrijeme**, listovi su vrijednosti tog atributa
- Elementi skupa za učenje **D** podjele se u tri grupe (**D**<sub>sunčano</sub>, **D**<sub>oblačno</sub> i **D**<sub>kišno</sub>) prema vrijednostima atributa **Vrijeme** (sunčano, oblačno, kišno)
- Za svaki takav podskup **D**<sub>sunčano</sub>, **D**<sub>oblačno</sub> i **D**<sub>kišno</sub> ponavlja se isti postupak

- Entropija unutar grane *sunčano* tj. skupa  $D_{\text{sunčano}}$

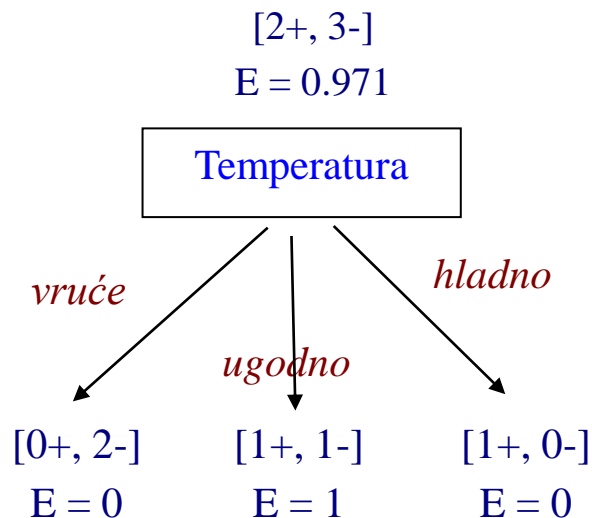
Vrijeme	Temperatura	Vlažnost	Vjetar	Igra
sunčano	vruće	velika	slab	NE
sunčano	vruće	velika	jak	NE
oblačno	vruće	velika	slab	DA
kišno	ugodno	velika	slab	DA
kišno	hladno	normalna	slab	DA
kišno	hladno	normalna	jak	NE
oblačno	hladno	normalna	jak	DA
sunčano	ugodno	velika	slab	NE
sunčano	hladno	normalna	slab	DA
kišno	ugodno	normalna	slab	DA
sunčano	ugodno	normalna	jak	DA
oblačno	ugodno	velika	jak	DA
oblačno	vruće	normalna	slab	DA
kišno	ugodno	velika	jak	NE

# PRIMJER



$$\text{Entropija}(D_{\text{sunčano}}) = \text{Entropija}([2+,3-]) = -\frac{2}{5}\log_2\frac{2}{5} - \frac{3}{5}\log_2\frac{3}{5} = 0.971$$

- Unutar grane *sunčano* računamo informacijske dobiti za tri atributa, **Temperatura**, **Vlažnost** i **Vjetar**:



$D_{\text{sunčano}}[2+,3-]$  označimo kao D

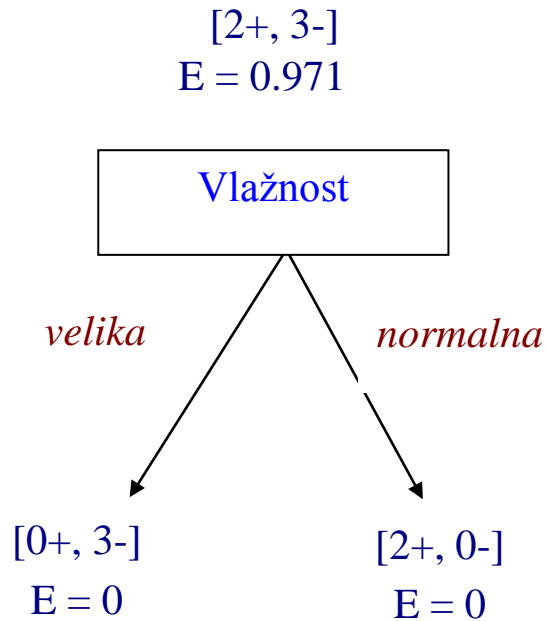
	<i>Temper.</i>	<i>Vlažnost</i>	<i>Vjetar</i>	
sunčano	vruće	velika	slab	<b>NE</b>
sunčano	vruće	velika	jak	<b>NE</b>
sunčano	ugodno	velika	slab	<b>NE</b>
sunčano	hladno	normalna	slab	<b>DA</b>
sunčano	ugodno	normalna	jak	<b>DA</b>

Informacijska\_dobit( $D_{\text{sunčano}}$ , Temperatura)


$$= 0.971 - (2/5) 0 - (2/5) 1 - (1/5) 0$$

$$= \mathbf{0.571}$$

# PRIMJER



$$\begin{aligned} & \text{Informacijska\_dobit}(D_{\text{sunčano}}, \text{Vlažnost}) \\ &= 0.971 - (3/5) 0 - (2/5) 0 \\ &= \mathbf{0.971} \end{aligned}$$

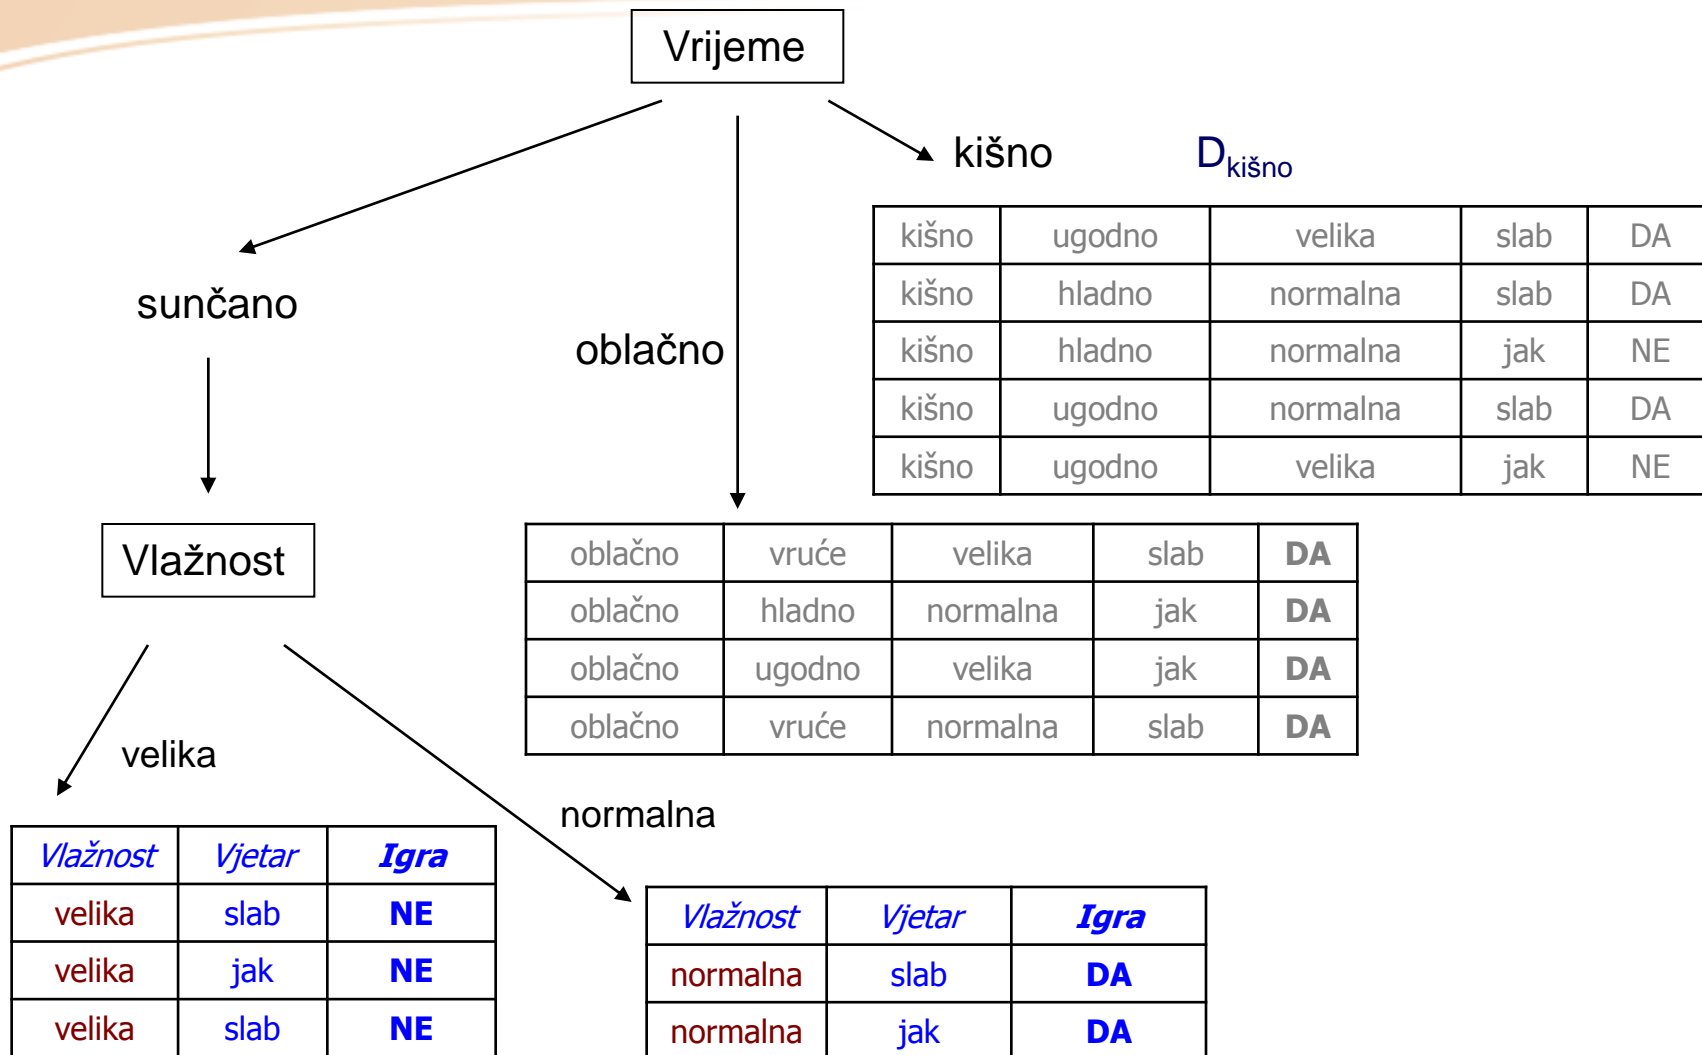


$$\begin{aligned} & \text{Informacijska\_dobit}(D_{\text{sunčano}}, \text{Vjetar}) \\ &= 0.971 - (2/5) 1 - (3/5) 0.918 \\ &= \mathbf{0.02} \end{aligned}$$



- Unutar grane *sunčano* najveću informacijsku dobit ima atribut **Vlažnost**, stoga je atribut **Vlažnost** čvor u drugoj razini stabla odluke niz granu *sunčano*
- Gore opisani postupak primjenjuje se na čvor **Vlažnost**. Razdjeljuje se skup primjera  $D_{\text{sunčano}}$  niz grane *normalna* (skup  $D_{\text{sunčano}}$ , **normalna**) i *velika* (skup  $D_{\text{sunčano}}$ , **velika**)

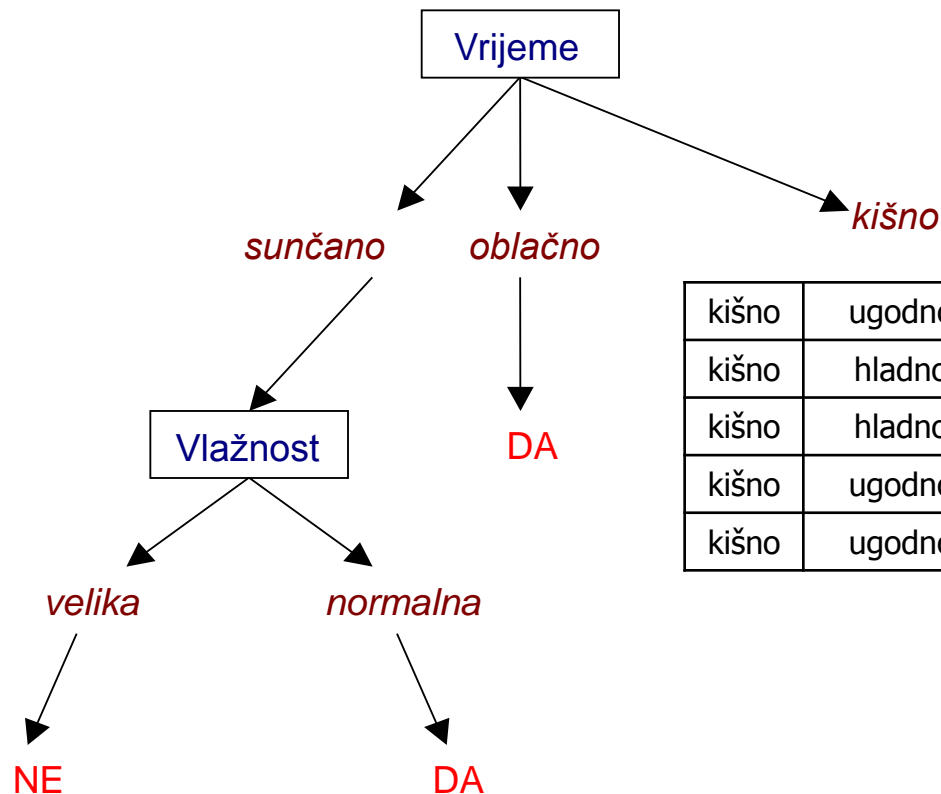
# PRIMJER



Zaustavljamo se – svi su primjeri iz iste klase – “NE”

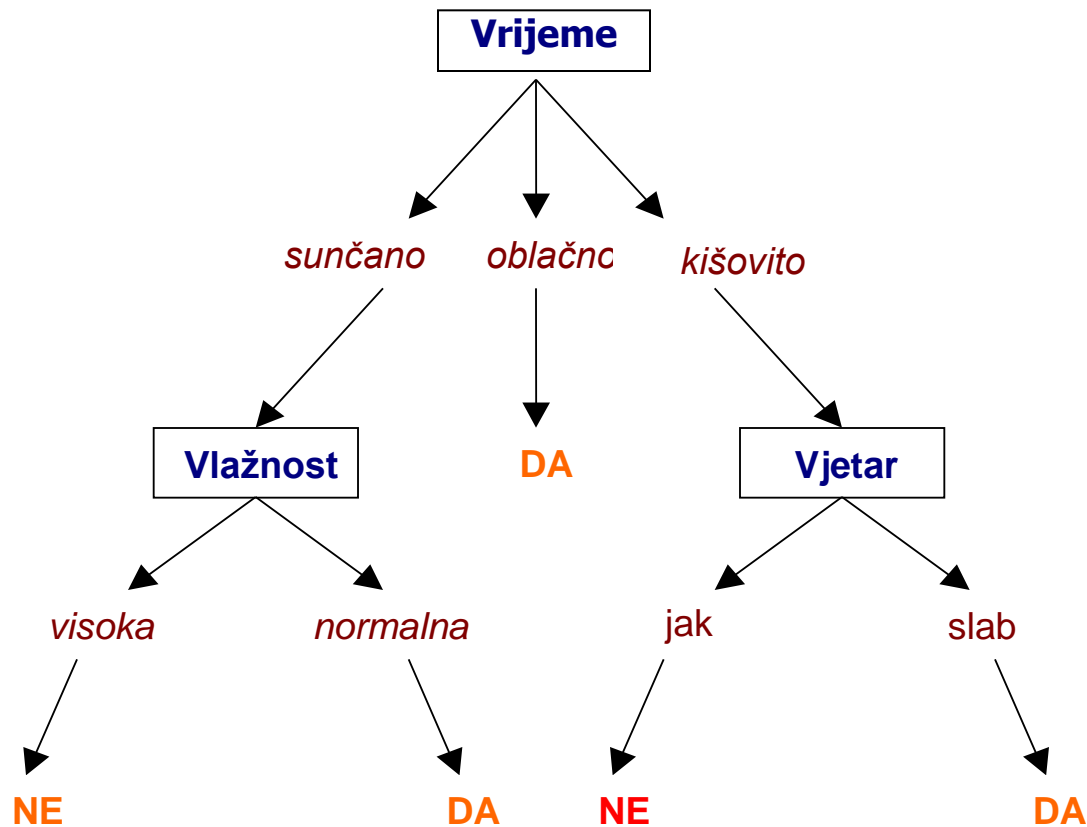
Zaustavljamo se – svi su primjeri iz iste klase – “DA”

- Da svi primjeri nisu iz iste klase, trebalo bi još dodati čvor za vrijednost atributa **Temperatura** ili **Vjetar**



kišno	ugodno	velika	slab	DA
kišno	hladno	normalna	slab	DA
kišno	hladno	normalna	jak	NE
kišno	ugodno	normalna	slab	DA
kišno	ugodno	velika	jak	NE

- Nakon analize  $D_{kišno}$ , tj. procjene informacijske dobiti za attribute **Temperatura**, **Vlažnost** i **Vjetar** konačno stablo odluke je oblika:



- **ID3(Primjeri, Ciljni\_atribut, Atributi)**

*Ciljni atribut je atribut čije vrijednosti trebaju biti određene stablom odluke. Atributi su lista drugih atributa koji mogu biti ispitani u postupku učenja stabla odluke. Algoritam vraća stablo odluke koje ispravno klasificira dane primjere.*

Stvori korijen stabla ROOT

Ako su svi primjeri pozitivni, vrati stablo s jednim čvorom čija je oznaka = +

Ako su svi primjeri negativni, vrati stablo s jednim čvorom čija je oznaka = -

Ako je atribut prazan, vrati stablo s jednim čvorom ROOT, s oznakom = najčešća vrijednost *Ciljnog atributa* u skupu  
(Q: kada se ovo događa?)

Inače

$A \leftarrow$  atribut iz skupa *Atributa* koji najbolje klasificira primjere (tj. ima najveću informacijsku dobit)

Atribut za odluku u korijenu je A tj.  $ROOT \leftarrow A$

**Za svaku** moguću vrijednost  $v_i$  od A

Dodaj novu granu stabla ispod korijena  
ROOT, koja odgovara testu  $A = v_i$

Neka  $D_{v_i}$  označava podskup skupa  
*Primjeri* koji imaju vrijednost  $v_i$  za atribut A

Ako je skup  $D_{v_i}$  prazan

Ispod nove grane dodaj završni čvor  
(list) čija je oznaka jednaka najčešće  
pojavljivanoj vrijednosti atributa  
*Ciljni\_atribut* u skupu  $D$

*(Q: kada se ovo događa?)*

Inače ispod nove grane dodaj stablo

$ID3(D_{v_i}, \text{Ciljni\_atribut}, \text{Atributi} \setminus \{A\})$

# GENERALIZIRANI ALGORITAM ( $K > 2$ klasa)

- Općenit slučaj je kada imamo  $N$  primjera razdijeljenih u skupove koji pripadaju razredima  $C_j$ ,  $j = 1, 2, 3, \dots, K$
- Broj primjera u razredu  $C_j$  neka je  $N_j$ . Svaki primjer ima attribute  $A_a$ ,  $a = 1, \dots, n$ . Svaki atribut ima vrijednosti  $V_{av}$ ,  $v = 1, \dots, M_a$ . (Radi jednostavnosti, pretpostavit ćemo da svi atributi imaju  $M$  vrijednosti.)
- Postupak ID3 za izgradnju stabla odluke je sljedeći:

Korak 1. *Izračunati početnu vrijednost entropije*. U skupu za učenje, pripadnost razredu je poznata za sve primjere. Zbog toga je početna entropija skupa  $D$  koji se sastoji od  $N$  primjera

$$\text{Entropija}(D) = \sum_{j=1}^K - \left( \frac{N_j}{N} \right) \log_2 \left( \frac{N_j}{N} \right) = \sum_{j=1}^K - P(C_j) \log_2 P(C_j)$$

- Korak 2. *Odabрати atribut koja će biti korijen stabla odluke.*
- a) Za svaki atribut  $A_a$ ,  $a=1, 2, 3, \dots, n$ , razdijeli originalni skup primjera na prvorazinske skupove prema vrijednostima  $V_{av}$  od mogućih  $M$  vrijednosti atributa  $A_a$ . Postoji  $N_{av}$  primjera u  $V_{av}$  grani, ali ti uzorci ne moraju nužno biti iz jednog razreda.
- b) Za svaki podskup grane  $V_{av}$ , broj primjera koji pripadaju razredu  $C_j$  je  $N_{av}(j)$ . Izračunati entropiju te grane koristeći relaciju

$$Entropija(D, A_a, v) = \sum_{j=1}^K - \left( \frac{N_{av}(j)}{N_{av}} \right) \log_2 \left( \frac{N_{av}(j)}{N_{av}} \right)$$



# GENERALIZIRANI ALGORITAM

Entropija sustava nakon testiranja atributa  $A_a$  je

$$Entropija(D, A_a) = \sum_{v=1}^M \sum_{j=1}^K \left( \frac{N_{av}}{\sum_v N_{av}} \right) \cdot \left[ - \left( \frac{N_{av}(j)}{N_{av}} \right) \log_2 \left( \frac{N_{av}(j)}{N_{av}} \right) \right]$$

- c) Pad entropije (tj. informacijska dobit) kao rezultat ispitivanja atributa  $A_a$  je

$$Informacijska\_dobit(a) = Entropija(D) - Entropija(D, A_a)$$

- d) Izabrati atribut  $A_{a^*}$  koji rezultira najvećom informacijskom dobiti, tj. za koju je  
*informacijska\_dobit(a\*) > informacijska\_dobit(a)* za svaki  $a=1, 2, 3, \dots, n, a \neq a^*$ .
- e) Atribut  $A_{a^*}$  postaje korijen stabla odluke

# GENERALIZIRANI ALGORITAM

- Korak 3. *Izgraditi sljedeću razinu stabla odluke.* Izabrati atribut  $A_a$ , koji će služiti kao prvorazinski čvor, takav da nakon testiranja  $A_a$  za **sve** grane dobijemo maksimalnu dobit informacijskog sadržaja ili maksimalni pad entropije
- Korak 4. *Ponavljati korake 1 do 3.* Nastavljati dok svi podskupovi ne budu iz jednog razreda tj. entropija sustava postane jednaka nuli

## Induktivne metode učenja:

- **Pretraživanje prostora hipoteza za onom koja najbolje odgovara primjerima za učenje**

Kakav prostor hipoteza pretražuje ID3?

- Svih mogućih stabala odluke, od praznog stabla prema složenijima koje ispravno klasificira primjere za učenje
- ID3 možemo promatrati kao pretraživanje prostora hipoteza metodom «uspona na vrh» (*engl. hill-climbing*) u kojem je heuristička funkcija (koja vodi pretraživanje) informacijska dobit
- Pohlepna metoda

## ID3 pretražuje potpun prostor hipoteza

- Prostor hipoteza ID3 je prostor svih mogućih funkcija s konačno diskretnih vrijednosti (u odnosu na broj atributa). Svaka takva funkcija se može predočiti stablom odluke pa ID3 izbjegava zamku pretraživanja nepotpunog prostora hipoteza koji ne sadrži ciljni koncept (npr. u slučaju kada su hipoteze u obliku konjunkcije atributa)

## ID3 pronalazi samo jednu hipotezu

- CE - nalazi sve hipoteze konzistentne s primjerima. Ne znamo koliko je još stabala odluke konzistentno s primjerima za učenje,
- Učenik ne može postaviti upit o primjeru koji će onda razriješiti između mogućih hipoteza

## **ID3 u izvornom obliku se ne vraća unatrag u postupku pretraživanja**

- To svojstvo ima isti nedostatak kao i pretraga metodom uspona na vrh – mogućnost da se zaglavi u lokalnom optimumu.

## **ID3 u svakom koraku koristi sve primjere za učenje da bi statistički rafinirao tekuću hipotezu**

- Prednost uporabe statističkog svojstva svih primjera za učenje (tj. informacijske dobiti) jest manja osjetljivost na pogreške u skupu primjera za učenje.  
Algoritmi CE i Find-S donose odluke u koracima (inkrementalno) na temelju jednog predočenog primjera

# INDUKTIVNA PRISTRANOST ALGORITMA ID3

- Induktivna pristranost je skup pretpostavki tako da skupa s primjerima za učenje deduktivno potvrđuju klasifikaciju koju određuje učenik na novom primjeru
- *ID3 - metoda »uspona na vrh» - prihvatanje prve odgovarajuće hipoteze*
- Na temelju čega ID3 može generalizirati i klasificirati još neviđene primjere?
- **Induktivna pristranost ID3:** Na temelju čega ID3 preferira jednu konzistentnu hipotezu u odnosu na drugu?
  - a) ID3 izabire kraće stablo prije nego dulje stablo
  - b) Izabire stablo koje stavlja attribute s većom informacijskom dobiti bliže korijenu

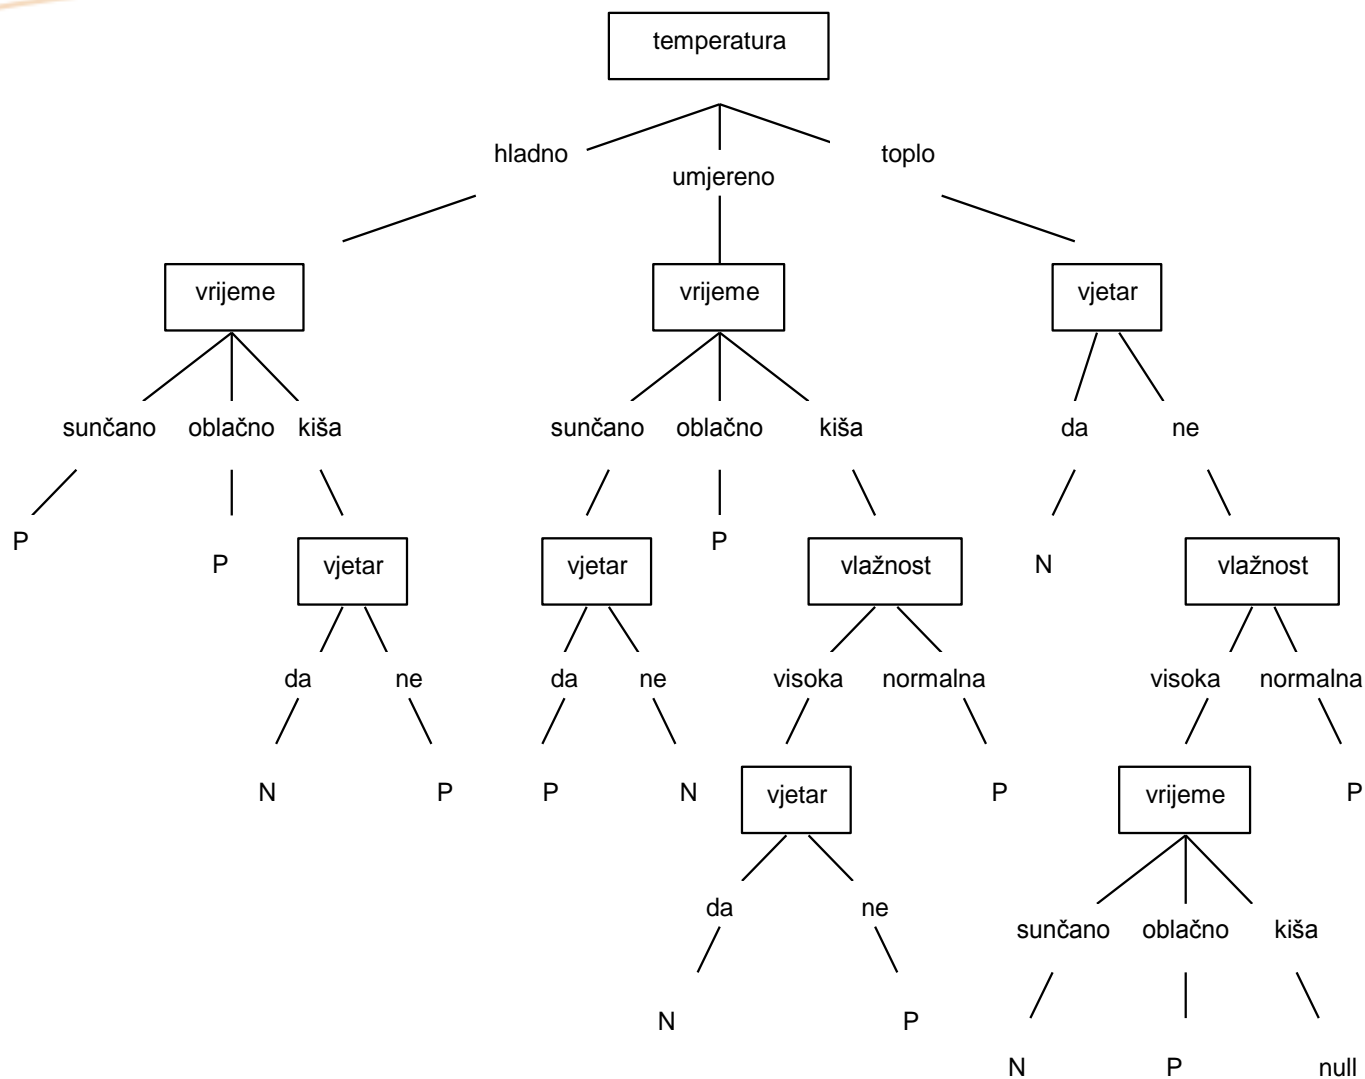
# INDUKTIVNA PRISTRANOST ALGORITMA ID3

**Približna induktivna pristranost ID3:**  
Preferiraju se kraća stabla odluke nad većima.

- Usporedba BFS (*engl. breadth first search*) i algoritma ID3

**Bolja približna induktivna pristranost ID3:**  
Preferiraju se kraća stabla odluke nad većima.  
Preferiraju se stabla koje stavljaju attribute s većom informacijskom dobiti bliže korijenu

# INDUKTIVNA PRISTRANOST ALGORITMA ID3





# INDUKTIVNA PRISTRANOST ALGORITMA ID3

- Jedan pristup zadatku zaključivanja bio bi generiranje svih mogućih stabala odluke koja ispravno klasificiraju uzorke iz skupa za učenje, te izabiranje najjednostavnijeg stabla. Broj takvih stabala je konačan, ali vrlo velik, pa je ovakav pristup primjenjiv jedino za manje zahtjevne zadatke
- ID3 je pogodan za zadatke za koje je karakteristično puno atributa i gdje se skup za učenje sastoji od puno uzoraka, ali ipak je moguće ostvariti prilično dobro stablo bez previše računanja
- Općenito, ID3 gradi jednostavna stabla odluke, ali pristup koji koristi ne garantira da se bolje stablo ne može pronaći

# PRISTRANOSTI RESTRIKCIJOM I PRISTRANOSTI PREFERENCIJOM

## Različiti tipovi induktivne pristranosti

	ID3	Eliminacija kandidata (CE)
<b><i>Prostor hipoteza</i></b> <i>koji se pretražuje</i>	Potpun	Nepotpun (onaj koji se može izraziti hipotezom)
<b><i>Način pretraživanja tog prostora</i></b>		
<b><i>Induktivna pristranost isključivo povezana s:</i></b>		
<b><i>Induktivna pristranost</i></b>		

# PRISTRANOSTI RESTRIKCIJOM I PRISTRANOSTI PREFERENCIJOM

## Različiti tipovi induktivne pristranosti

	ID3	Eliminacija kandidata (CE)
<b><i>Prostor hipoteza</i></b> <i>koji se pretražuje</i>	Potpun	Nepotpun (onaj koji se može izraziti hipotezom)
<b><i>Način pretraživanja tog prostora</i></b>	Nepotpuno pretraživanje (od jednostavnijih do složenijih) dok ne nađe hipotezu konzistentnu s podacima	Temeljito (potpuno) pretraživanje
<b><i>Induktivna pristranost isključivo povezana s:</i></b>		
<b><i>Induktivna pristranost</i></b>		

# PRISTRANOSTI RESTRIKCIJOM I PRISTRANOSTI PREFERENCIJOM

## Različiti tipovi induktivne pristranosti

	ID3	Eliminacija kandidata (CE)
<b><i>Prostor hipoteza</i></b> <i>koji se pretražuje</i>	Potpun	Nepotpun (onaj koji se može izraziti hipotezom)
<b><i>Način pretraživanja tog prostora</i></b>	Nepotpuno pretraživanje (od jednostavnijih do složenijih) dok ne nađe hipotezu konzistentnu s podacima	Temeljito (potpuno) pretraživanje
<b><i>Induktivna pristranost isključivo povezana s:</i></b>	uređajnom strategijom pretraživanja hipoteza	ekspresivnom moći predstavljanja hipoteza
<b><i>Induktivna pristranost</i></b>		

# PRISTRANOSTI RESTRIKCIJOM I PRISTRANOSTI PREFERENCIJOM

## Različiti tipovi induktivne pristranosti

	ID3	Eliminacija kandidata (CE)
<b><i>Prostor hipoteza koji se pretražuje</i></b>	Potpun	Nepotpun (onaj koji se može izraziti hipotezom)
<b><i>Način pretraživanja tog prostora</i></b>	Nepotpuno pretraživanje (od jednostavnijih do složenijih) dok ne nađe hipotezu konzistentnu s podacima	Temeljito (potpuno) pretraživanje
<b><i>Induktivna pristranost isključivo povezana s:</i></b>	uređajnom strategijom pretraživanja hipoteza	ekspresivnom moći predstavljanja hipoteza
<b><i>Induktivna pristranost</i></b>	<u>Preferencija</u> nekih hipoteza nad drugima	<u>Restrikcija</u> skupa razmatranih hipoteza

# PRISTRANOSTI RESTRIKCIJOM I PRISTRANOSTI PREFERENCIJOM

## Različiti tipovi induktivne pristranosti

	ID3	Eliminacija kandidata (CE)
<b><i>Prostor hipoteza</i></b> <i>koji se pretražuje</i>	Potpun	Nepotpun (onaj koji se može izraziti hipotezom)
<b><i>Način pretraživanja tog prostora</i></b>	Nepotpuno pretraživanje (od jednostavnijih do složenijih) dok ne nađe hipotezu konzistentnu s podacima	Temeljito (potpuno) pretraživanje
<b><i>Induktivna pristranost isključivo povezana s:</i></b>	uređajnom strategijom pretraživanja hipoteza	ekspresivnom moći predstavljanja hipoteza
<b><i>Induktivna pristranost</i></b>	<u>Preferencija</u> nekih hipoteza nad drugima	<u>Restrikcija</u> skupa razmatranih hipoteza
	<b>Priistranost preferencijom ili pristranost pretraživanja</b> (engl. <i>preference bias, search bias</i> )	<b>Priistranost restrikcijom ili pristranost jezika</b> (engl. <i>preference bias, search bias</i> )



# PRISTRANOSTI RESTRIKCIJOM I PRISTRANOSTI PREFERENCIJOM

- Koja je pristranost općenito poželjnija?
- Neki sustavi strojnog učenja kombiniraju ove dvije vrste pristranosti

*Primjer*

Sustav koji uči igrati igru DAME:

<b>Priistranost jezika</b>	<b>Priistranost pretraživanja</b>
Izbor linearne evaluacijske funkcije značajki igre	Izbor algoritma LMS u odnosu na druge moguće algoritme za podešavanja parametara

# ZAŠTO PREFERIRATI KRAĆE HIPOTEZE?

- Filozofsko pitanje



1320.g. William of Occam

"Pluralitas non est ponenda sine neccesitate"

Primjer: Za neki skup podataka može biti nebrojeno teorija koje ih objašnjavaju. Četiri točke na pravcu – postoji bezbroj krivulja koje se mogu povući kroz te točke, no pravac je najjednostavnija



# PRAKTIČNI PROBLEMI VEZANI ZA UČENJE STABLA ODLUKE

- određivanje dubine rasta stabla
- atributi s kontinuiranim vrijednostima
- mjera za izbor atributa
- nedostajuće vrijednosti atributa
- efikasnost računanja

Proširenje ID3 – algoritam C4.5 (Quinlan, 1993)

# IZBJEGAVANJE PREKOMJERNE NAUČENOSTI PODATAKA

- Algoritam ID3 – rast stabla dok se svi podaci pravilno ne klasificiraju
- To je problem ako su:
  - podaci sa šumom
  - skup za učenje je premalen.
- Tada može doći do **prenaučenosti** (*engl. overfit*) stabla odluke

# IZBJEGAVANJE PREKOMJERNE NAUČENOSTI PODATAKA

- Algoritam ID3 – rast stabla dok se svi podaci pravilno ne klasificiraju
- To je problem ako su:
  - podaci sa šumom
  - skup za učenje je premalen.
- Tada može doći do **prenaučenosti** (*engl. overfit*) stabla odluke

## *Definicija*

- Neka je dan prostor hipoteza  $H$ . **Hipoteza  $h \in H$  je prenaučena** ako postoji hipoteza  $h' \in H$  takva da  $h$  ima manju pogrešku nego  $h'$  na na primjerima za učenje, ali  $h'$  ima manju pogrešku nego  $h$  na cijelom prostoru primjera


# IZBJEGAVANJE PREKOMJERNE NAUČENOSTI PODATAKA

## *Primjer prenaučenosti*

- Pretpostavimo da je dodan 15. primjer u skup primjera koji je pogrešno klasificiran kao Igra = NE umjesto Igra = DA.
- Primjetimo da bi postojeće stablo ispravno klasificiralo ispravan primjer (igra = DA) u istu granu kao i 9. i 11. primjer

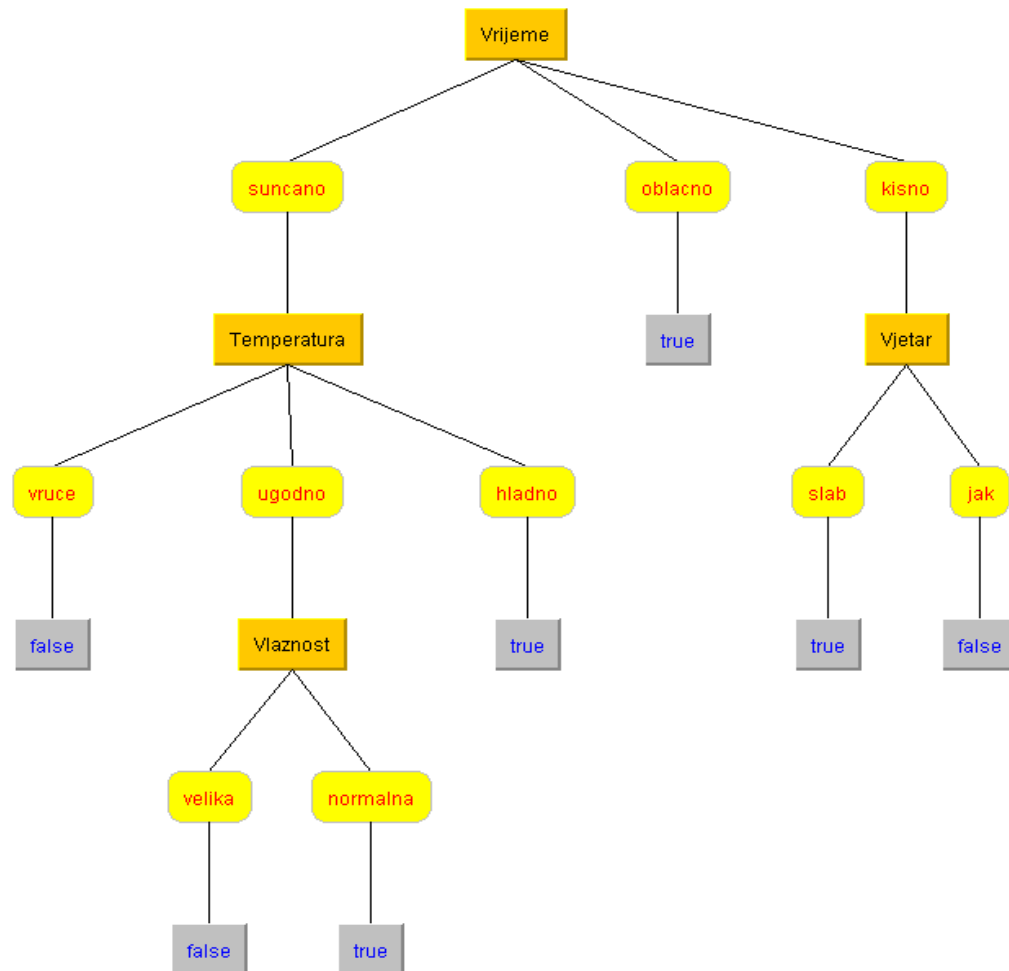
	Vrijeme	Temperatura	Vlažnost	Vjetar	Igra
15.	sunčano	vruće	normalna	jak	NE

# IZBJEGAVANJE PREKOMJERNE NAUČENOSTI PODATAKA



# IZBJEGAVANJE PREKOMJERNE NAUČENOSTI PODATAKA

	Vrijeme	Temperatura	Vlažnost	Vjetar	Igra
15.	sunčano	vruće	normalna	jak	NE



# IZBJEGAVANJE PREKOMJERNE NAUČENOSTI PODATAKA

## Izbjegavanje prenaučenosti – dva pristupa:

- zaustavljanje rasta stabla prije savršene klasifikacije primjera za učenje
- naknadno podrezivanje prenaučenog stabla → uspješniji pristup u praksi

## Kako odrediti razumnu veličinu stabla?

- uvođenjem posebnog skupa podataka za vrednovanje (najčešće u praksi)  
skup primjera:
    - skup za učenje (*engl. training set*)
    - skup za vrednovanje (*engl. validation set*) → osigurava da ne dođe do prenaučenosti
- ideja*: mala je vjerojatnost da skup za vrednovanje ima ista slučajna odstupanja kao i skup za učenje

# IZBJEGAVANJE PREKOMJERNE NAUČENOSTI PODATAKA

- **uporaba statističkih testova** - testiranja je li uvođenje ili uklanjanje čvora donosi poboljšanje u odnosu na cjelokupnu distribuciju (a ne samo na primjerima za učenje, primjer: Quinlan, 1986.,  $\chi^2$  test)
- **uvođenje eksplicitne mjere kompleksnosti** kodiranja primjera za učenje i stabla odluke i zaustavljanja kada je ta mjera minimalna.  
*Primjer. Načelo najmanje duljine opisa (engl. minimum description length principle)*



# SMANJIVANJE POGREŠKE PODREZIVANJEM

**Podrezivanje stabla** znači uklanjanje čvora i pripadnog podstabla koje ima korijen u tom čvoru, zamjenjujući ga s listom tako da se listu pridruži najčešća vrijednost ciljnog atributa u tom podčvoru.

- Svaki je čvor kandidat za podrezivanje
- Čvorovi se uklanjaju samo ako se dobiveno podrezano stablo ne ponaša lošije na skupu za vrednovanje
- Na taj se način uklanjaju čvorovi dodani zbog slučajnih nepravilnosti u skupu za učenje kojih nema u skupu za vrednovanje

# SMANJIVANJE POGREŠKE PODREZIVANJEM


- Uklanjanje je iterativan postupak – traje sve dok se ne počne smanjivati točnost na skupu za vrednovanje

Tri skupa:

- skup za učenje
  - skup za vrednovanje – (ovaj skup vodi postupak podrezivanja)
  - skup za testiranje
- Ovakav pristup podrazumijeva veliki skup ulaznih podataka

# NAKNADNO PODREZIVANJE PRAVILA

- Ideja:



- Ovu metodu koristi C4.5.
- 1. Nauči stablo odluke iz skupa za učenje sve dok svi podaci ne pristaju dobro, dozvoljavajući prenaučenosť
- 2. Pretvori stablo u ekvivalentan skup pravila stvarajući jedno pravilo za svaku stazu od korijena do lista
- 3. Podrezuj (poopći) pravila uklanjajući bilo koji preduvjet koji rezultira u poboljšanju procijenjene točnosti
- 4. Složi podrezana pravila po procijenjenoj točnosti i razmatraj ih u tom nizu kod klasificiranja primjera

# NAKNADNO PODREZIVANJE PRAVILA

- Primjer: Najljevija grana stabla odluke (Quinlanov primjer)

**AKO** (**Vrijeme** = *sunčano*)  $\wedge$  (**Vlažnost** = *visoka* )

**ONDA** (**Igranje\_tenisa** = **NE**)

- Pravilo se podrezuje tako da se uklanjaju uvjeti iz lijevog dijela pravila ((**Vrijeme** = *sunčano*) i (**Vlažnost** = *visoka* ) ) čije uklanjanje ne pogoršava procijenjenu točnost

## Kako procijeniti točnost pravila?

1. Uporaba skupa za vrednovanje (*engl. validation set*)  $\neq$  od skupa za učenje
2. Računanje točnosti pravila na skupu za učenje i računanju donje granice intervala pouzdanosti pretpostavljajući binomnu distribuciju. Ta se donja granica smatra mjerom preformanse pravila. Procjena donje granice intervala pouzdanosti ovisi o veličini skupa za testiranje

## Zašto konvertirati stablo odluke u pravila?

1. Pravila omogućuju razlikovanje konteksta u kojem je čvor korišten. Čvor se razmatra zasebno u svakom pravilu i kojem sudjeluje (zato što grana koja daje pravilo prolazi kroz taj čvor). Ako se čvor uklanja u stablu – istodobno se uklanja prisutnost tog uvjeta (čvora) u svim pravilima (u kojima se taj uvjet pojavljuje na lijevoj strani)
2. Uklanja se razlika između testiranja atributa koji se nalaze na dnu stabla (blizu listu) ili pri vrhu (korijenu)
3. Pravila povećavaju čitljivost i razumljivost

# ATRIBUTI S KONTINUIRANIM VRIJEDNOSTIMA

- Atributi koji se testiraju morali su imati konačan skup diskretnih vrijednosti. Ovo ograničenje može se ukloniti dinamičkim definiranjem novih diskretnih vrijednosti atributa u obliku skupa diskretnih intervala
- $A$  - atribut s kontinuiranim vrijednostima
- $c \in \text{domena}(A)$
- Algoritam definira novi Booleov atribut  $A_c$  takav da je  **$A_c$  istinit** ako  $\text{vrijednost}(A) < c$  inače  **$A_c$  lažan**

# ATRIBUTI S KONTINUIRANIM VRIJEDNOSTIMA

## Kako odabrati najbolju vrijednost za $c$ ?

*Primjer*

- Pretpostavimo da primjeri za učenje pridruženi nekom čvoru imaju sljedeće kontinuirane vrijednosti za atribut **Temperatura** i za ciljni koncept **Igranje\_tenisa**

Temperatura	40	48	60	72	80	90
Igranje_tenisa	NE	NE	DA	DA	DA	NE

- Želimo izabrati  $c$  tako da imamo najveću informacijsku dobit



# ATRIBUTI S KONTINUIRANIM VRIJEDNOSTIMA

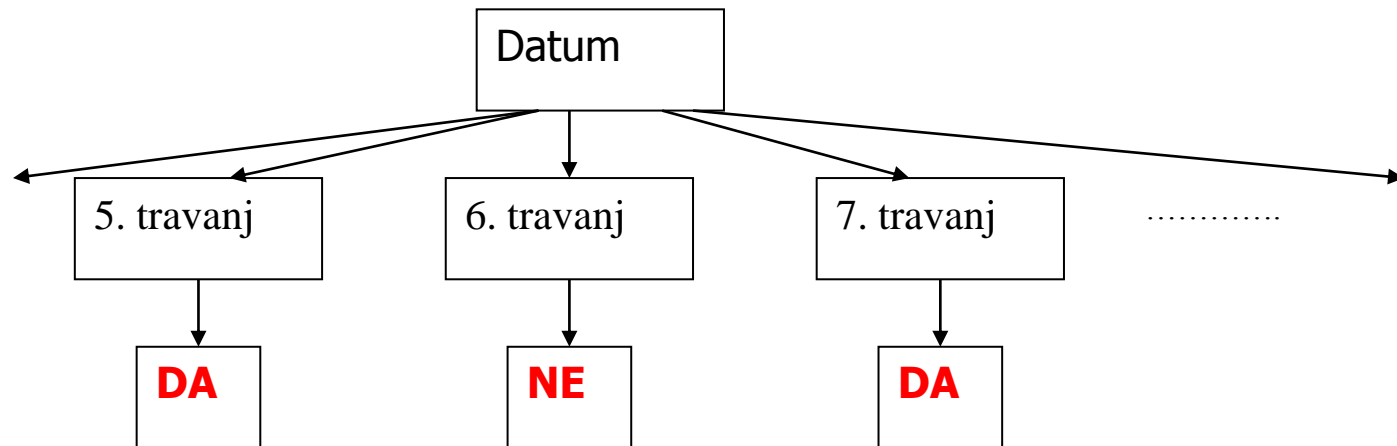
1	Vrijednosti atributa A slože se u rastućem redoslijedu.	<i>Već učinjeno u tablici</i>
2	Odrede se one susjedne vrijednosti atributa koje se razlikuju u klasifikaciji ciljnog atributa.	(48, 60) i (80, 90)
3	Nađe se srednja vrijednost takvih vrijednosti atributa. Te srednje vrijednosti čine kandidate za graničnu vrijednost $c$	$c = (48 + 60) / 2 = 54$ $c = (80 + 90) / 2 = 85$
4	Računa se informacijska dobit za svaki takav kandidat za graničnu vrijednost $c$	$IG(\text{Temperatura}_{>54})$ $IG(\text{Temperatura}_{>85})$
5	Odabire se $c$ s najvećom vrijednošću $I(\text{Temperatura}_{>c})$	$IG(\text{Temperatura}_{>54})$

# ALTERNATIVNE MJERE ZA IZBOR ATRIBUTA

- Informacijska dobit sadrži pristranost koja preferira attribute s više vrijednosti

## *Primjer*

- Kada bi dodali atribut *Datum* u tablicu tada bi datum imao najveću informacijsku dobit zato što bi savršeno predviđao vrijednost ciljnog atributa



- Ovakvo bi se stablo ponašalo loše na novim podacima

# ALTERNATIVNE MJERE ZA IZBOR ATRIBUTA

- Alternativna mjera **Omjer dobitka** (*engl. gain ratio*) (Quinlan, 1986) koji kažnjava attribute poput *Datum* zbog člana **informacijska podijeljenost** (*engl. split information*) koji je osjetljiv na to koliko široko i uniformno atribut dijeli podatke

$$\text{Informacijska\_podijeljenost}(D, A) = - \sum_{v=1}^M \frac{|D_v|}{|D|} \log_2 \frac{|D_v|}{|D|}$$

- $D_1, \dots, D_v, \dots, D_M$  su podskupovi skupa primjera  $D$  koji nastaju particijom  $D$  s obzirom na vrijednost  $v$  atributa  $A$   
(*Entropija u odnosu na vrijednosti atributa*)

## Zadatak

Kolika je informacijska podijeljenost atributa:

- koji uniformno distribuira vrijednosti poput atributa *Datum*?
- Booleovog atributa koji dijeli  $n$  primjera točno na pola?

# ALTERNATIVNE MJERE ZA IZBOR ATRIBUTA

Odgovor:

1.  $\log_2 M$
2. 1

- Omjer dobitka se definira

$$Omjer\_dobitka(D, A) = \frac{Informacijska\_dobit(D, A)}{Informacijska\_podijeljenost(D, A)}$$

- Ako dva atributa imaju istu informacijsku dobit preferirati će se onaj koji ima manju informacijsku podijeljenost

# ALTERNATIVNE MJERE ZA IZBOR ATRIBUTA

## Što ako je nazivnik blizu 0?

- Za  $|D_v| \approx |D|$ , nazivnik je blizu 0 što čini omjer dobitka vrlo velik ili nedefiniran za attribute koji imaju skoro svuda istu vrijednost
- *Izbjegavanje takve situacije:* Za sve attribute se računa informacijska dobit, a omjer dobitka se računa samo za one attribute koji imaju informacijsku dobit iznad prosječne vrijednosti (a to su upravo problematični atributi poput atributa *Datum*)

# NEDOSTAJUĆE VRIJEDNOSTI

- Pretpostavimo da u nekom čvoru stabla trebamo računati informacijsku dobit atributa  $A$  te da postoji primjer  $(x, y)$  za koje je vrijednost atributa nepoznata

*Primjer:*

$A = \text{Vjetar}$

# NEDOSTAJUĆE VRIJEDNOSTI

	Vrijeme	Temperatura	Vlažnost	Vjetar	Igra
1	sunčano	vruće	velika	slab	NE
2	sunčano	vruće	velika	jak	NE
3	oblačno	vruće	velika	slab	DA
4	kišno	ugodno	velika	slab	DA
5	kišno	hladno	normalna	slab	DA
6	kišno	hladno	normalna	jak	NE
7	oblačno	hladno	normalna	<b>jak</b>	DA
8	sunčano	ugodno	velika	slab	NE
9	sunčano	hladno	normalna	slab	DA
10	kišno	ugodno	normalna	slab	DA
11	sunčano	ugodno	normalna	jak	DA
12	oblačno	ugodno	velika	jak	DA
13	oblačno	vruće	normalna	slab	DA
14	kišno	ugodno	velika	jak	NE
	sunčano[2+,3-] oblačno[4+,0-] kišno[3+,2-]	hladno[3+,1-] ugodno[4+,2-] vruće[2+,2-]	vel. [3+, 4-] norm. [6+,1-]	<b>slab [6+, 2-]</b> <b>jak [2+, 3-]</b>	[9+, 5-]

## Prvi pristup:

1. Pridjeliti najčešću vrijednost tog atributa na temelju primjera u tom čvoru ili
2. Pridjeliti najčešću vrijednost tog atributa koja se pojavljuje među primjerima klasificiranim s  $y$  u tom čvoru

## Drugi pristup:

- Pridjeljivanje vjerojatnosti svakoj mogućoj vrijednosti atributa u tom čvoru. Vjerojatnost se temelji na relativnim frekvencijama poznatih primjera



# NEDOSTAJUĆE VRIJEDNOSTI

*Primjer:*

Vjerojatnost  $P(Vjetar=jak) = 5/13$

Vjerojatnost  $P(Vjetar=slab) = 8/13$

Sada se ti omjeri koriste za računanje informacijske dobiti

$A = Vjetar$

Vrijednost ( $Vjetar$ ) = *slab, jak*

$D = [9+, 5-]$  - izračunato na temelju 14 primjera

$D_{slab} \leftarrow [6+, 2-]$ .... ukupno 8 primjera	} izračunato na temelju 13 primjera
$D_{jak} \leftarrow [2+, 3-]$ .... ukupno 5 primjera	

# NEDOSTAJUĆE VRIJEDNOSTI

- **Informacijska dobit (*Gain*)** zbog odjeljivanja primjera skupa  $D$  na temelju vrijednosti atributa **Vjetar** jest

$$\text{Informacijska\_dobit}(D, A) \equiv \text{Entropija}(D) - \sum_{v \in \text{Vrijednosti}(A)} \frac{|D_v|}{|D|} \text{Entropija}(D_v)$$

- Najprije računamo entropije skupova  $D$ ,  $D_{\text{slab}}$ ,  $D_{\text{jak}}$

$$\text{Entropija}(\mathbf{D}) = 0.940 \quad (\text{vidi raniji primjer!})$$

$$\text{Entropija}(\mathbf{D}_{\text{slab}}) = \text{Entropija}([6+, 2-]) = -(6/8)\log_2(6/8) - (2/8)\log_2(2/8) = 0.811$$

$$\text{Entropija}(\mathbf{D}_{\text{jak}}) = \text{Entropija}([2+, 3-]) = -(3/5)\log_2(3/5) - (2/5)\log_2(2/5) = 0.970$$

# NEDOSTAJUĆE VRIJEDNOSTI

***Informacijska\_dobit(D, Vjetar) ≡***

$$\equiv \textit{Entropija}(\mathbf{D}) - (8/13)\textit{Entropija}(\mathbf{D}_{\text{slab}}) - (5/13)\textit{Entropija}(\mathbf{D}_{\text{jak}}) =$$

$$\equiv 0.940 - (8/13)0.811 - (5/13)0.970 =$$

$$\equiv \mathbf{0.06784}$$