STROJNO UČENJE

2. Domaća Zadaća

Krešimir Špes 0036419866 ak. god. 2011. / 2012.

a) prvo ćemo procijeniti parametar μ_{ML} i \sum_{ML} po sljedećim formulama:

$$\hat{\boldsymbol{\mu}}_{\mathrm{ML}} = \frac{1}{N} \sum_{i=1}^{N} \mathbf{x}^{(i)}. \quad \hat{\boldsymbol{\Sigma}}_{\mathrm{ML}} = \frac{1}{N} \sum_{i=1}^{N} (\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}}_{\mathrm{ML}}) (\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}}_{\mathrm{ML}})^{\mathrm{T}}$$

$$\mu_{ML} = [-0.5320 -0.6550 -0.5560 -1.7550]$$

Radi korekcije pristranosti ∑_{ML} ćemo korigirati sa N/(1 – N) zbog malog broja primjera

```
\Sigma_{\text{ML}} = [ 2.4418     0.6105     1.2935     0.0102     0.6105     0.5002     0.2914     0.1758     1.2935     0.2914     1.9438     -0.0264     0.0102     0.1758     -0.0264     0.4008 1
```

vrijednosti su izračunate pomoću matlaba, kod je dan u zad1 a.m datodeci.

b)

Mahalanobisova udaljenost: 4.0301

Ekulidska udaljenost: 2.8284

Nije jednako ekulidskoj udaljenosti jer je Mahalanobisova udaljenost neosjetljiva na razlike u varijanci između pojedinih dimenzija i na korelacije između varijabli.

Rekao bih da je to dobro jer nam u statističkom pogledu Mahalanobisova udaljenost daje iskoristljiviju mjeru udaljenosti. To je pogotovo korisno u više od 3 dimenzije jer euklidske udaljenosti ionako nemožemo vizualizirati za više od 3 dimenzije.

c)

Varijable su statistički nezavisne ako vrijedi P(X, Y) = P(X) * P(Y)

Kako bi dokazali (ne)zavisnost varijable, izračunamo kovarijaciju dviju varijabla. Tako je kovarijacija za x1 i x2 = -0.252568 što znači da nisu nezavisne.

Ne možemo definitivno odgovoriti da li su varijable nezavisno jer iako možemo dokazati da su varijable nekorelirane, to ne znači da varijable nisu nelinearno korelirane (koeficijent korelacije mjeri samo linearnu zavisnost varijabli)

U nastavku je dan python kod za izračun kovarijacije varijabli x1 i x2:

```
 \begin{aligned} &x1 = [-1.28, -1.83, 3.24, -2.47, -1.07, -1.58, -1.00, -0.53, 0.50, 0.70] \\ &x2 = [-1.51, -0.99, 0.11, -1.95, 0.15, 0.06, -0.95, -0.67, -0.91, 0.11] \\ &E1 = 0 \\ &\text{for i in } x1: \\ &E1 += i \\ &E1 /= len(x1) \end{aligned}   E2 = 0 \\ &\text{for i in } x2: \\ &E2 += i \\ &E2 /= len(x2)   E12 = 0 \\ &\text{for i in range}(0, len(x1)): \\ &E12 += x1[i]^*x2[i] \\ &E12 /= len(x1)^*len(x1)   cov = E12 - E1^*E2
```

print "cov:", cov