5. U ovom zadatku trebate izgraditi multivarijatni generativni model za dvije klase s kontinuiranim značajkama. U datoteci su-2011-dz2-zad5-podatci.txt nalaze se primjeri koji su nastali iz 12 višedimenzijskih Gaussovih izvora. Prva dva stupca označavaju koordinate primjera, a treći stupac označava klasu primjera. U programima Matlab/Octave podatci se mogu učitati na ovaj način:

podatci=dlmread('su-2011-dz2-zad5-podatci.txt');
X = podatci(:, 1:2);
y = podatci(:, 3);

 (a) Nasumično odaberite dvije klase (od mogućih 12). Napišite koje ste klase odabrali.

Odabrao sam klase 5 i 6.

(b) Za odabrane klase izračunajte  $\hat{\boldsymbol{\mu}}_j$ ,  $\hat{\boldsymbol{\Sigma}}_j$  i  $\hat{P}(\mathcal{C}_j)$ .

$$\mu_5 = [8\ 2] \qquad \qquad \mu_6 = [-5\ -9]$$
 
$$\Sigma_5 = [5.7237\ -0.1508] \qquad \qquad \Sigma_6 = [6.2592\ -0.7477] \\ [-0.1508\ 3.7113] \qquad \qquad [-0.7477\ 8.8559]$$
 
$$P(C_5) = 0.3852 \qquad \qquad P(C_6) = 0.6148$$

- (c) Skup podijelite na skup za učenje, skup za provjeru, i skup za ispitivanje u omjeru 3:1:1.
- (d) Izgradite tri modela različite složenosti: (1) model s različitim kovarijacijskim matricama, (2) model s dijeljenom kovarijacijskom matricom i (3) model s dijeljenom izotropnom kovarijacijskom matricom.

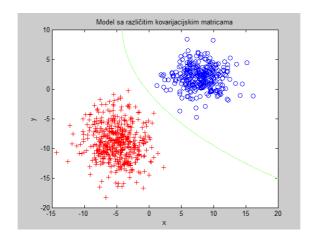
(1) 
$$h_j(\mathbf{x}) = -\frac{1}{2} \ln |\mathbf{\Sigma}_j| - \frac{1}{2} (\mathbf{x}^{\mathrm{T}} \mathbf{\Sigma}_j^{-1} \mathbf{x} - 2\mathbf{x}^{\mathrm{T}} \mathbf{\Sigma}_j^{-1} \boldsymbol{\mu}_j + \boldsymbol{\mu}_j^{\mathrm{T}} \mathbf{\Sigma}_j^{-1} \boldsymbol{\mu}_j) + \ln P(\mathcal{C}_j)$$

(2) 
$$h_j(\mathbf{x}) = \mathbf{x}^{\mathrm{T}} \mathbf{\Sigma}^{-1} \boldsymbol{\mu}_j - \frac{1}{2} \boldsymbol{\mu}_j^{\mathrm{T}} \mathbf{\Sigma}^{-1} \boldsymbol{\mu}_j + \ln P(\mathcal{C}_j)$$

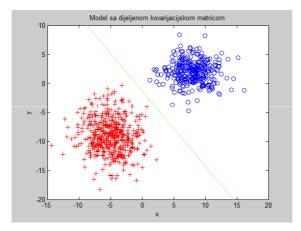
(3) 
$$h_j(\mathbf{x}) = -\frac{1}{2\sigma^2} \sum_{i=1}^{N} (x_i - \mu_{ij})^2 + \ln P(\mathcal{C}_j)$$

(e) Za sva tri modela nacrtajte primjere iz prve i druge klase te decizijsku granicu između dviju klasa. Decizijska granica dobiva se rješavanjem jednadžbe  $P(C_1|x) = P(C_2|x)$ . Funkcijom ezplot mogu se crtati implicitne jednadžbe.

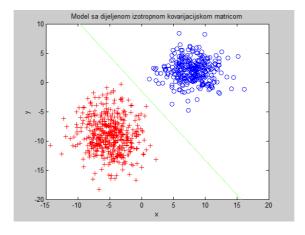
Slike se nalaze u mapi slike.



Slika 1. Model sa različitim kovarijacijskim matricama [model (1)]



Slika 2. Model sa dijeljenom kovarijacijskom matricom [model (2)]



Slika 3. Model sa dijeljenom izotropnom kovarijacijskom matricom [model (3)]

(f) Izračunajte pogrešku generalizacije za svaki od tri modela na skupu za provjeru. Odaberite optimalan model. Obrazložite svoju odluku.

> Model (1), greška generalizacije: 0 Model (2), greška generalizacije: 0 Model (3), greška generalizacije: 0

Greška generalizacije mi je 0 na sva tri modela, jer su razredi koje sam odabrao linearno razdvojivi. I to toliko razdvojivi, da bi čak i slijepa koka ubola dobru decizijsku funkciju.

Budući da mi je podjednaka greška generalizacije na svim modelima, odabirem najjednostavniji model po principu Occamove britve, a to je model (3).

(g) Naučite odabrani model na uniji skupa za učenje i skupa za provjeru (4/5 ukupnog skupa). Izračunajte pogrešku generalizacije takvog modela na skupu za ispitivanje (1/5 ukupnog skupa). Je li ona manja ili veća od one koju ste dobili na skupu za provjeru u zadatku 5f? Komentirajte zašto je to tako.

Opet sam računao za sve jer mi se sviđa rezultat © Model (1), greška generalizacije: 0 Model (2), greška generalizacije: 0 Model (3), greška generalizacije: 0

Niti je manja, niti je veća, nego je jednaka :D!

Zašto? Zato što su razredi linearno razdvojivi, i već prilikom učenja je nađena decizijska funkcija koja dobro odvaja razrede, i budući da nemamo outlinera, greška generalizacije je konstantno nula. ©